

Česká zemědělská univerzita v Praze

Technická fakulta

Katedra matematiky a fyziky



Diplomová práce

**Matematický model predikce výroby energie podle
předpovědi počasí pro PV elektrárny**

Jakub Hampejs

© 2025 ČZU v Praze

ČESKÁ ZEMĚDĚLSKÁ UNIVERZITA V PRAZE

Technická fakulta

ZADÁNÍ DIPLOMOVÉ PRÁCE

Bc. Jakub Hampejs

Informační a řídicí technika v agropotravinářském komplexu

Název práce

Matematický model predikce výroby energie podle předpovědi počasí pro PV elektrárny

Název anglicky

Mathematical model of prediction of energy production according to weather forecast for PV power plants

Cíle práce

- Vytvořit matematický model predikce výroby elektrické energie ve fotovoltaické elektrárně podle předpovědi počasí.
- Otestovat tento model v provozu reálné elektrárny. Učinit vlastní závěry ohledně použitelnosti tohoto modelu.

Metodika

Aplikace neuronových sítí na PV elektrárny s využitím vysoce kvalitních meteorologických satelitních a radarových snímků spolu s dalšími souvisejícími meteorologickými parametry. Krátkodobá predikce slunečního záření dopadajícího na solární panely s následnou projekcí celkového výkonu solární elektrárny v závislosti na čase. Porovnání skutečného a predikovaného výkonu PV elektrárny. Vlastní závěry ohledně významu vytvořeného modelu.

Doporučený rozsah práce

cca 45 stran

Klíčová slova

Solární energie, fotovoltaika, PV panel, neuronová síť

Doporučené zdroje informací

- Beránek, V., Olšan, T., Libra, M., Poulek, V., Sedláček, J., Dang, M.Q., Tyukhov, I.I., 2018. New Monitoring System for Photovoltaic Power Plants' Management. *Energies* 11 (10), 2495. doi:10.3390/en11102495.
- Haegel, N.M., Kurtz, S.R., 2021. Global Progress Toward Renewable Electricity: Tracking the Role of Solar. *IEEE J. Photovoltaics*, 11 (6), 1335–1342. doi:10.1109/JPHOTOV.2021.3104149.
- Hernández-Callejo, L., Gallardo-Saavedra, S., Alonso-Gómez, V., 2019. A review of photovoltaic systems: Design, operation and maintenance. *Solar Energy*, 188, 426–440, doi: 10.1016/j.solener.2019.06.017.
- LIBRA, Martin; POULEK, Vladislav. *Fotovoltaika : teorie i praxe využití solární energie*. Praha: ILSA, 2009. ISBN 978-80-904311-0-2.
- Libra, M., Mrázek, D., Tyukhov, I., Severová, L., Poulek, V., Mach, J., Šubrt, T., Beránek, V., Svoboda, R., Sedláček, J., Reduced real lifetime of PV panels – Economic consequences. *Solar Energy*, 2023, 259, 229–234, doi: 10.1016/j.solener.2023.04.063.
- Libra, M., Petřík, T., Poulek, V., Tyukhov, I.I., Kouřím, P., 2021. Changes in the Efficiency of Photovoltaic Energy Conversion in Temperature Range With Extreme Limits. *IEEE J. Photovoltaics* 11 (6), 1476–1481. doi:10.1109/JPHOTOV.2021.3108484.
- Lillo-Sánchez, L., López-Lara, G., Vera-Medina, J., Pérez-Aparicio, E., Lillo-Bravo, I. (2021). Degradation analysis of photovoltaic modules after operating for 22 years. A case study with comparisons, *Solar Energy*, v. 222, p. 84–94, ISSN 0038-092X, <https://doi.org/10.1016/j.solener.2021.04.026>. (<https://www.sciencedirect.com/science/article/pii/S0038092X21003133>).
- Poulek, V., Šafránková, J., Černá, L., Libra, M., Beránek, V., Finsterle, T., Hrzina, P., 2021. PV Panel and PV Inverter Damages Caused by Combination of Edge Delamination, Water Penetration, and High String Voltage in Moderate Climate. *IEEE Journal of Photovoltaics*, 11(2), 561–565, 2021, doi: 10.1109/JPHOTOV.2021.3050984.
- Šafránková, J., Šubrt, T., Mach, J., Beránek, V., Poulek, V., Severová, L., Libra, M., Životní cyklus fotovoltaických elektráren – ekonomické zhodnocení. *Jemná mechanika a optika*, 2023, 68, 195–198, ISSN 0447-6441.

Předběžný termín obhajoby

2024/2025 LS – TF

Vedoucí práce

prof. Ing. Martin Libra, CSc., dr. h. c.

Garantující pracoviště

Katedra fyziky

Elektronicky schváleno dne 12. 11. 2023

prof. Ing. Martin Libra, CSc., dr. h. c.

Vedoucí katedry

Elektronicky schváleno dne 01. 03. 2024

doc. Ing. Jiří Mašek, Ph.D.

Děkan

V Praze dne 30. 03. 2025

Čestné prohlášení

Prohlašuji, že svou diplomovou práci "Matematický model predikce výroby energie podle předpovědi počasí pro PV elektrárny" jsem vypracoval samostatně pod vedením vedoucího diplomové práce a s použitím odborné literatury a dalších informačních zdrojů, které jsou citovány v práci a uvedeny v seznamu použitých zdrojů na konci práce. Jako autor uvedené diplomové práce dále prohlašuji, že jsem v souvislosti s jejím vytvořením neporušil autorská práva třetích osob.

V Praze dne 31.3.2025

Poděkování

Rád bych touto cestou poděkoval vedoucímu diplomové práce prof. Ing. Martinovi Librovi, CSc., dr. h. c. za možnost výběru zajímavého a aktuálního tématu diplomové práce a za jeho cenné rady a vstřícné konzultace.

Matematický model predikce výroby energie podle předpovědi počasí pro PV elektrárny

Abstrakt

Tato diplomová práce se zabývá problematikou krátkodobé predikce výkonu fotovoltaické elektrárny s využitím pokročilých modelů strojového učení. Cílem bylo navrhnout a implementovat predikční model, který by dosahoval co nejvyšší přesnosti při odhadu budoucího výkonu elektrárny v závislosti na meteorologických podmínkách.

V práci byly testovány různé přístupy k predikci, včetně historických průměrů, fyzikálních modelů a metod hlubokého učení, jako jsou rekurentní neuronové sítě (LSTM). Modely byly trénovány na reálných datech z fotovoltaické elektrárny ABA, přičemž nejlepší výsledky byly dosaženy kombinací neuronových sítí a meteorologických předpovědí. Výsledný model byl nasazen do provozu a je dostupný online na platformě Hugging Face, kde umožňuje predikci výkonu na pět dní dopředu.

Závěrem byly diskutovány možnosti dalšího zlepšení predikčního modelu, například využití kratších časových vzorků nebo kombinace fyzikálních a datově řízených modelů. Výsledky této práce mají praktické uplatnění při optimalizaci provozu fotovoltaických elektráren a přispívají k efektivnějšímu využití obnovitelných zdrojů energie.

Klíčová slova: Solární energie, fotovoltaika, PV panel, fotovoltaická elektrárna, neuronová síť, strojové učení, meteorologická data, predikce výkonu fotovoltaické elektrárny, hluboké učení, fyzikální modely

Mathematical model of prediction of energy production according to weather forecast for PV power plants

Abstract

This thesis addresses the issue of short-term photovoltaic power forecasting using advanced machine learning models. The goal was to design and implement a predictive model that achieves the highest possible accuracy in estimating future power output based on meteorological conditions.

Various forecasting approaches were tested, including historical averages, physical models, and deep learning methods such as recurrent neural networks (LSTM). The models were trained on real data from the ABA photovoltaic power plant, with the best results achieved through a combination of neural networks and weather forecasts. The final model was deployed and is available online on the Hugging Face platform, enabling power predictions up to five days in advance.

Finally, potential improvements to the predictive model were discussed, such as using shorter time samples or combining physical and data-driven models. The results of this work have practical applications in optimizing the operation of photovoltaic power plants and contribute to the more efficient use of renewable energy sources.

Keywords: Solar energy, photovoltaics, PV panel, photovoltaic power plant, neural network, machine learning, meteorological data, photovoltaic power prediction, deep learning, physical models.

Obsah

1 Úvod.....	1
2 Cíl práce a metodika	3
2.1 Cíl práce	3
2.2 Metodika.....	3
3 Fotovoltaika	4
3.1.1 Architektura PV elektrárny	5
3.1.2 Výkon solárního modulu.....	6
3.2 Dopadající sluneční záření	7
4 Faktory ovlivňující výkon FVE.....	9
4.1 Meteorologické faktory	9
4.1.1 Intenzita slunečního záření a úhel dopadu	9
4.1.2 Teplota	9
4.1.3 Odrazivost	10
4.1.4 Stínění	10
4.1.5 Znečištění	11
4.2 Konstrukční faktory.....	11
4.2.1 Degradace.....	11
4.2.2 Invertory.....	12
4.2.3 Odpor ve vodičích.....	12
5 Strojové učení	13
5.1 Typy strojového učení	14
5.1.1 Učení s učitelem (supervised learning).....	14
5.1.2 Učení bez učitele (unsupervised learning).....	15
5.1.3 Učení s posilováním (Reinforcement Learning).....	16
5.2 Hlavní výzvy strojového učení.....	16
5.2.1 Dostatek a kvalita trénovacích dat	17
5.2.2 Šum a chybějící hodnoty.....	17
5.2.3 Redundance a nerelevantní vlastnosti	17
5.2.4 Inženýrství rysů (Feature Engineering).....	17
5.3 Normalizace rysů (Feature Scaling).....	17
5.3.1 Min-max škálování (normalizace):	18
5.3.2 Standardizace (z-skórová normalizace):	18
5.3.3 Yeo-Johnsonova transformace	19
5.4 Dávkové učení (Batch Learning) a kontinuální učení (Online Learning).....	19
5.4.1 Dávkové učení (batch learning)	19

5.4.2	Kontinuální učení (online Learning).....	20
5.5	Rozdělení dat pro trénování a testování modelu	21
5.5.1	Trénovací sada	21
5.5.2	Validační sada.....	21
5.5.3	Testovací sada.....	21
5.6	Ztrátové funkce	21
5.6.1	Střední kvadratická chyba – Mean Squared Error (MSE):	22
5.6.2	Střední kvadratická odchylka – Root mean square error (RMSE):	22
5.6.3	Střední absolutní chyba – Mean absolute error (MAE):.....	23
5.7	Metriky pro hodnocení modelu.....	23
5.7.1	Střední absolutní procentní chyba – Mean Absolute Percentage Error (MAPE) 23	
5.7.2	Symetrická střední absolutní procentní chyba – symmetric Mean Absolute Percentage Error (sMAPE).....	24
5.7.3	Koeficient determinace – R square (R^2)	25
5.7.4	Průměrná systematická odchylka – Mean Bias Error (MBE).....	25
5.8	Přeučení a podučení modelu (overfitting, underfitting).....	26
6	Hluboké učení zaměřené na predikci výkonu FVE	27
6.1	Perceptron	29
6.2	Aktivační funkce	32
6.2.1	Lineární funkce	32
6.2.2	Hyperbolický tangens	32
6.2.3	RELU (Rectified Linear Unit)	33
6.3	Trénování neuronové sítě	34
6.4	Hluboké učení pro časové řady	35
6.4.1	Křížová validace časových řad	36
6.4.1.1	Jednoduché časové rozdělení (Simple Time Split Validation).....	37
6.4.1.2	Křížová validace klouzavého okna (Rolling Window Cross-Validation)	37
6.4.1.3	Křížová validace rozšiřujícího se okna (Expanding Window Cross-Validation)38	
6.4.2	Rekurentní neuronové sítě (RNN)	39
6.4.3	Algoritmus dlouhé krátkodobé paměti	40
6.4.3.1	Výpočty v LSTM buňce	42
6.4.4	Konvoluční neuronové sítě (CNN)	43
7	Příprava a analýza dat.....	44
7.1	Fotovoltaická elektrárna ABA	44
7.2	Analýza dat.....	45

7.2.1	Data od společnosti Solarmon.....	45
7.2.2	Data od společnosti Amper Meteo.....	46
7.2.3	Data z OpenMeteo	47
7.2.4	Transformace dat pro model	47
7.3	Analyzovaná data	48
7.4	Sezonní analýza:.....	50
7.5	Korelační analýza	57
7.5.1	Globální sluneční záření (RAD)	58
7.5.2	Teplota panelů (tp)	58
7.5.3	Ozon (Ozone).....	58
7.5.4	Vlhkost vzduchu (humidity)	58
7.5.5	Oblačnost (cloud_cover).....	58
7.5.6	Povrchový atmosférický tlak (surface_pressure).....	58
7.5.7	Prachové částice (PM10)	59
7.5.8	Složky větru ve směru východ-západ a sever-jih (wind_u, wind_v).....	59
7.5.9	Časové proměnné (sin_hour, cos_hour, sin_day_of_year, cos_day_of_year) 59	
7.5.10	Maximální hodnota globálního slunečního záření (RAD_MAX).....	59
7.5.11	Přímé sluneční záření (DNI)	59
7.5.12	Difuzní sluneční záření (DHI).....	60
7.5.13	Krátkovlnné sluneční záření (shortwave_radiation)	60
7.5.14	Úhel dopadu slunečních paprsků na panel (AOI)	60
7.5.15	Koeficient úhlu dopadu záření (IAM).....	60
7.5.16	Okolní teplota (T2M)	60
7.5.17	Rychlost větru (WS10) a směr větru (wind_direction_10m).....	60
7.5.18	Zenit slunce (ZENITH).....	61
7.5.19	Azimut slunce (AZIMUTH)	61
7.5.20	Srážky (precipitation).....	61
7.5.21	Teplota rosného bodu (dew_point)	61
8	Zpracování vstupních rysů.....	63
8.1	Sluneční záření	63
8.2	Výkon	64
8.3	Teplota panelů	65
8.4	Koncentrace ozónu	65
8.5	Vlhkost vzduchu.....	66
8.6	Oblačnost.....	67
8.7	Povrchový atmosférický tlak.....	68
8.8	Prachové částice PM10	69
8.9	Složky větru ve směru východ-západ a sever-jih.....	70

8.10 Časové proměnné	71
9 Tvorba modelů pro predikci výkonu FVE	72
9.1 Referenční model na základě historických průměrů	74
9.2 Referenční fyzikální model	75
9.3 Referenční fyzikální model s využitím korekčního koeficientu IAM	77
9.4 Modely s využitím neuronových sítí	79
9.4.1 Model pro predikci výkonu na následujících 8 hodin na základě historických dat	80
9.4.2 Model s predikcí výkonu se zahrnutím předpovědi počasí	87
10 Výsledky a diskuse	93
11 Závěr	95
12 Seznam použitých zdrojů	I
13 Přílohy	IV

Seznam obrázků

Obr. 1. Solární článek a solární modul jako základní komponenty fotovoltaiky [2].	5
Obr. 2. Typická struktura solární elektrárny [3].	6
Obr. 3. Jednotlivé složky slunečního záření dopadající na solární modul [2].	7
Obr. 4. Úhel azimutu slunce se mění v závislosti na geografické poloze [4].	8
Obr. 5. Strojové učení může přispět k objevování nových poznatků [22].	13
Obr. 6. Označená tréninková sada pro klasifikaci spamu (příklad učení s učitelem) [22]. ..	14
Obr. 7. Regresní úloha, predikce hodnoty na základě rysu [22].	15
Obr. 8. Shlukování v učení bez učitele [22].	15
Obr. 9. Učení posilováním (Reinforcement Learning) [22].	16
Obr. 10. Model je natrénován a nasazen do produkce, kde se průběžně učí z nových dat [22].	20
Obr. 11. Průběh procesu učení.	27
Obr. 12. Princip hlubokého učení [21].	28
Obr. 13. Perceptron[30]	29
Obr. 14. Plně propojená síť [30].	31
Obr. 15. Gradientní sestup [22].	35
Obr. 16. 3D tenzor časových dat [21].	36
Obr. 17. Příklad oken a horizontů pro bitcoinová data [34].	36
Obr. 18. Jednoduché časové rozdělení [35].	37
Obr. 19. Křížová validace klouzavého okna [35].	38
Obr. 20. Křížová validace rozšiřujícího se okna [35].	39
Obr. 21. Rekurentní neuron a rozvinutí sítě v čase [22].	40
Obr. 22. LSTM buňka [22].	41
Obr. 23. Extrakce hierarchického učení rysů [21].	44
Obr. 24. Korelační matice vstupních proměnných.	62
Obr. 25. Korelační matice ostatních proměnných.	62
Obr. 26. Architektura predikčního modelu s vrstvami Conv1D a LSTM.	80

Seznam tabulek

Tabulka 1. Hodnoty chybových metrik pro predikční model výkonu využívající průměrné hodnoty.....	74
Tabulka 2. Hodnoty chybových metrik pro predikční fyzikální model výkonu s Me.	76
Tabulka 3. Hodnoty chybových metrik pro predikční fyzikální model výkonu využívající IAM pro Me.	78
Tabulka 4. Výčet hyperparametrů modelu.....	82
Tabulka 5. Hodnotící metriky pro model predikující výkon na následujících 8 hodin82	
Tabulka 6. Výčet hyperparametrů modelu využívající předpověď počasí.	88
Tabulka 7. Hodnotící metriky pro model s využitím předpovědi počasí predikující výkon na následujících 24 hodin.....	88
Tabulka 8. Přehled hodnotících metrik pro všechny modely.....	94

Seznam grafů

Graf 1. Lineární aktivační funkce [31].....	32
Graf 2. Hyperbolický tangens [31].	33
Graf 3. RELU [31].	33
Graf 4. Vynesený výkon za období 28.8.2019 až 4.10.2024 měření.	49
Graf 5. Výkon FVE v prvních deseti dnech.....	49
Graf 6. Průměrný výkon v měsících.	49
Graf 7. Průměrný výkon FVE v jednotlivých měsících.....	50
Graf 8. Průměrný výkon v ročních obdobích.....	51
Graf 9. Průměrný denní průběh výkonu.....	52
Graf 10. Průměrný výkon za měsíc červen a leden s odpovídajícím slunečním zářením....	52
Graf 11. Součet vyprodukované energie za jednotlivé měsíce.	53
Graf 12. Součet vyprodukované energie za jednotlivé měsíce.	53
Graf 13. Průměrný výkon FVE ABA podle měsíců za jednotlivé roky.	54
Graf 14. Měsíční průměrné teploty panelů (tp) a okolní (to).....	55
Graf 15. Průměrné měsíční hodnoty slunečního záření.	56
Graf 16. Průměrná měsíční rychlost větru.	57
Graf 17. Histogram hodnot slunečního záření (RAD).	63
Graf 18. Histogramy RAD po transformaci Yeo-Johnson (vlevo) a následné normalizaci Min-Max (vpravo).....	64
Graf 19. Histogram hodnot výkonu.	64
Graf 20. Histogramy výkonu po transformaci Yeo-Johnson (vlevo) a následné normalizaci Min-Max (vpravo).....	65
Graf 21. Histogram teploty panelů (vlevo) a Min-Max normalizaci (vpravo).	65
Graf 22. Histogram koncentrace ozónu (vlevo) a Min-Max normalizaci (vpravo).	66
Graf 23. Histogram vlhkosti vzduchu.	66
Graf 24. Histogram vlhkosti vzduchu po Yeo-Johnson transformaci (vlevo) a následné Min-Max normalizaci (vpravo).....	67
Graf 25. Histogram oblačnosti.	68
Graf 26. Histogram oblačnosti po Yeo-Johnson transformaci (vlevo) a následné Min-Max normalizaci (vpravo).	68
Graf 27. Histogram povrchového atmosférického tlaku (vlevo) a Min-Max normalizaci (vpravo).....	69

Graf 28. Histogram prachových částic.	69
Graf 29. Histogram prachových částic po Yeo-Johnson transformaci (vlevo) a následně Min-Max normalizaci (vpravo).	70
Graf 30. Histogramy rychlosti větru ve směru východ–západ (horní řada) a sever–jih (dolní řada) před a po normalizaci.	71
Graf 31. Histogramy časových proměnných sin_hour, cos_hour, sin_day_of_year a cos_day_of_year.	72
Graf 32. Srovnání skutečného a predikovaného výkonu FVE z průměrných historických hodnot.	75
Graf 33. Srovnání skutečného a predikovaného výkonu FVE z průměrných hodnot pro prvních 300 hodnot v testovací sadě.	75
Graf 34. Porovnání skutečného a predikovaného výkonu fyzikálním modelem s využitím Me.	77
Graf 35. Porovnání skutečného a predikovaného výkonu fyzikálním modelem s využitím Me pro prvních 300 hodnot v testovací sadě.	77
Graf 36. Srovnání skutečného a predikovaného výkonu FVE s korekcí úhlu pomocí IAM pro Me.	79
Graf 37. Srovnání skutečného a predikovaného výkonu FVE s korekcí úhlu pomocí IAM pro Me pro prvních 300 hodnot v testovací sadě.	79
Graf 38. Průběh ztrátové funkce.	83
Graf 39. Průběhy predikcí se skutečným výkonem v jednotlivých hodinách.	84
Graf 40. Průběhy predikcí a skutečných výkonů v jednotlivých hodinách pro prvních 300 hodnot v testovací sadě.	85
Graf 41. Průměrná důležitost rysů dle SHAP analýzy.	86
Graf 42. Průběh ztrátové funkce.	90
Graf 43. Průběhy predikcí se skutečným výkonem v jednotlivých hodinách.	91
Graf 44. Průběhy predikcí a skutečných výkonů v jednotlivých hodinách pro prvních 300 hodnot v testovací sadě.	92

Seznam rovnic

Rovnice 1. Výpočet účinnosti [2].	6
Rovnice 2. Složky celkového slunečního záření [2].	7
Rovnice 3. Výpočet výkonu solárního modulu [5].	9
Rovnice 4. Min-max škálování [22].	18
Rovnice 5. Standardizace [22].	18
Rovnice 6. Yeo-Johnsonova transformace [23].	19
Rovnice 7. Ztrátová funkce MSE [22].	22
Rovnice 8. Ztrátová funkce RMSE [22].	22
Rovnice 9. Ztrátová funkce MAE [22].	23
Rovnice 10. Střední absolutní procentní chyba (MAPE) [25].	24
Rovnice 11. Symetrická střední absolutní procentní chyba [25].	24
Rovnice 12. Koeficient determinace [26].	25
Rovnice 13. Průměrná systematická odchylka [28].	26
Rovnice 14. Výpočet výstupní hodnoty perceptronu [30].	29
Rovnice 15. Výpočet výstupní hodnoty perceptronu v lineární algebře [30].	30
Rovnice 16. Lineární aktivační funkce [31].	32
Rovnice 17. Definice hyperbolického tangens [31].	33

Rovnice 18. Definice RELU [31].	33
Rovnice 19. Výpočet proměnné $\sin_hour$	48
Rovnice 20. Výpočet proměnné $\cos_hour$	48
Rovnice 21. Výpočet proměnné $\sin_day_of_year$	48
Rovnice 22. Výpočet proměnné $\cos_day_of_year$	48
Rovnice 23. Výpočet síly větru ve směru východ-západ.	48
Rovnice 24. Výpočet síly větru ve směru sever-jih.	48

Seznam použitých zkratk

FVE	Fotovoltaická elektrárna
AOI	Angle of Incidence
IAM	Incidence Angle Modifier
PVGIS	Photovoltaic Geographical Information System
MAE	Mean Absolute Error
sMAPE	Symmetric Mean Absolute Percentage Error
MBE	Mean Bias Error
MSE	Mean Squared Error
RMSE	Root Mean Squared Error
MAPE	Mean Absolute Percentage Error
R^2	Koeficient determinace
DC	Direct Current
AC	Alternating Current
Wp	Watt-Peak
AM	Air Mass
SVM	Support Vector Machine
AI	Artificial Intelligence
RNN	Recurrent Neural Network
LSTM	Long Short-Term Memory
CNN	Convolutional Neural Network

1 Úvod

V posledním desetiletí fotovoltaika v České republice zaznamenala výrazný růst, a to především díky podpoře Evropské unie, která v reakci na rostoucí obavy o klimatické změny a potřebu snižování emisí skleníkových plynů intenzivně dotuje obnovitelné zdroje energie. Snižující se cena fotovoltaických panelů a rostoucí účinnosti těchto technologií činí fotovoltaiku stále atraktivnějším zdrojem energie.

Tato práce se zaměřuje na modelování a predikci výkonu fotovoltaických elektráren, což je klíčový faktor pro efektivní plánování jejich provozu a integrace do energetických sítí. Přesné predikce mohou nejen optimalizovat výrobu energie, minimalizovat ztráty a zlepšit stabilitu sítě, ale také představují ekonomickou výhodu. Díky přesnější predikci výkonu je možné efektivněji obchodovat s elektřinou na energetických trzích, maximalizovat zisky a lépe reagovat na fluktuace cen. V práci vypracovaný model bude testován v prostředí reálné elektrárny a jeho výsledky budou zhodnoceny, aby se ukázalo, jak může přispět k lepšímu řízení fotovoltaických elektráren.

Práce M. Libry et al. [1] porovnává skutečnou výrobu elektřiny ve vybraných fotovoltaických elektrárnách s očekávanými hodnotami z modelu PVGIS (Photovoltaic Geographical Information System). Výsledkem porovnání bylo, že reálná výroba byla o více než 10 % vyšší. To naznačuje, že standardní predikční modely nemusí vždy přesně zachytit specifické podmínky konkrétních lokalit, jako jsou mikroklimatické vlivy (např. lokální teplotní rozdíly, proudění vzduchu či vlhkost), konstrukční vlastnosti elektrárny (např. orientace panelů, jejich sklon nebo technologie chlazení) a další environmentální faktory, například zastínění, znečištění ovzduší či dynamické změny světelných podmínek. Tato práce se proto zaměřuje na vývoj pokročilého modelu využívajícího hluboké učení, který lépe zohlední aktuální meteorologické podmínky a krátkodobou variabilitu výkonu fotovoltaických elektráren[1].

Teoretická část práce nejprve popisuje fyzikální principy fotovoltaiky, dále se zabývá nominálním výkonem fotovoltaického modulu, standardní architekturou fotovoltaické elektrárny a faktory ovlivňujícími efektivitu výroby elektrické energie. Následuje část věnovaná strojovému a hlubokému učení se zaměřením na neuronové sítě a jejich architektur určených pro predikci sekvenčních řad, které jsou vhodné právě pro předpovídání výkonu fotovoltaických elektráren.

Praktická část práce se zaměřuje na vývoj a implementaci matematického modelu pro krátkodobou predikci výroby elektrické energie z fotovoltaické elektrárny. Modely byly navrhovány a testovány postupně – od nejjednodušších přístupů, jako jsou historické průměry, přes fyzikální modely (využívající knihovnu pvlib) až po pokročilé modely využívající hlubokého učení.

K implementaci těchto pokročilých modelů byla použita knihovna TensorFlow, resp. Keras, vyvíjená společností Google, která patří mezi nejpoužívanější frameworky pro práci s hlubokým učením. Vývoj probíhal ve vývojovém prostředí Google Colaboratory.

Jednotlivé modely byly porovnávány z hlediska přesnosti predikcí pomocí hodnotících metrik MAE (Mean Absolute Error), sMAPE (Symmetric Mean Absolute Percentage Error), MBE (Mean Bias Error) a R^2 (koeficient determinace), což umožnilo objektivní posouzení přesnosti predikcí jednotlivých metod.

Na základě modelu, který dosahoval nejlepších výsledků v hodnocení přesnosti predikcí, byla následně vytvořena webová aplikace umožňující vizualizaci predikovaného výkonu testované fotovoltaické elektrárny v reálném čase.

2 Cíl práce a metodika

2.1 Cíl práce

Cílem práce je navrhnout, implementovat a vyhodnotit model pro krátkodobou predikci výkonu fotovoltaické elektrárny ABA. Tento model by měl využívat historická data, meteorologické předpovědi a moderní metody strojového učení, především neuronové sítě, k dosažení co nejpřesnějších odhadů výkonu elektrárny. Práce se zaměřuje na optimalizaci těchto predikcí a následné nasazení nejlepšího modelu do praxe, čímž přispívá k efektivnějšímu využívání obnovitelných zdrojů energie a zvyšování provozní účinnosti fotovoltaických elektráren.

2.2 Metodika

Nejprve bylo nutné identifikovat klíčové faktory ovlivňující výkon fotovoltaické elektrárny. Následně bylo nutné získat dostatečně rozsáhlou a relevantní datovou sadu primárně pro trénink neuronové sítě. Tyto datové sady byly poskytnuty společnostmi Amper Meteo, Solarmon a Open-Meteo.

Poté byly testovány různé přístupy k predikci výkonu FVE, počínaje jednoduchými modely založenými na průměrných historických hodnotách pro danou hodinu, přes fyzikální modely, až po pokročilé metody hlubokého učení.

Pro pokročilé modely založené na neuronových sítích bylo nutné moudře vybrat a normalizovat vstupní rysy. Ty byly zvoleny na základě korelační analýzy i experimentálního testování. Dále pro zlepšení přesnosti modelu bylo provedeno inženýrství rysů – například vytvoření časových rysů, aby model správně reflektoval sezónní cykly, nebo úprava meteorologických rysů. U rychlosti a směru větru se predikční přesnost modelů zlepšila rozkladem těchto veličin na složky ve směru východ–západ a sever–jih.

Dále bylo nutné stanovit vhodné hodnotící metriky, které umožní objektivně porovnat přesnost predikcí jednotlivých modelů. Na základě experimentů byla následně vybrána optimální architektura a následně hyperparametry modelu.

Nakonec byl vybrán model s nejvyšší přesností predikce a byl nasazen na online platformu, kde umožňuje predikovat výkon FVE v reálném čase na následující dny.


3 Fotovoltaika

Fotovoltaický jev pomocí solárních článků umožňuje přímou přeměnu slunečního záření na elektrickou energii [2].

Základním komponentem každé fotovoltaické elektrárny je solární článek (Obr. 1). Tento článek je vyroben z polovodičového materiálu, nejčastěji z křemíku. Následně se provádí tzv. doping, při kterém se do materiálu zavádějí cizí atomy, což způsobuje změnu jeho vlastností a vytváří se p-n přechod, který v krystalové struktuře generuje elektrické pole.

Když světlo dopadá na solární článek, dochází k fotovoltaickému efektu, při kterém se excitované nosiče náboje uvolňují z krystalických vazeb a pohybují se elektrickým polem směrem k vnějším kontaktům. V důsledku toho se na těchto kontaktech vytváří napětí přibližně 0,5 V. Proud nakrátko závisí především na intenzitě slunečního záření a ploše článku a pohybuje se v intervalu mezi 0 a 10 A [2].


Aby bylo možné dosáhnout požadovaného napětí, jsou jednotlivé články spojovány do série v solárních modulech. Kromě toho jsou solární články (Obr. 1) v modulech mechanicky chráněny a utěsněny proti vlivům prostředí, jako je například vnikání vlhkosti [2].



Obr. 1. Solární článek a solární modul jako základní komponenty fotovoltaiky [2].

3.1.1 Architektura PV elektrárny

Obrázek níže (*Obr. 2*) ukazuje typickou strukturu solární elektrárny. Sluneční světlo dopadá na fotovoltaické moduly, které generují stejnosměrný proud (DC), jenž je veden do invertorů. Invertory přeměňují stejnosměrný proud na střídavý proud (AC), který je transformátory převeden na úroveň napětí v síti, a nakonec je přes rozvaděč veden do sítě. Případně místo okamžitého dodávání energie do veřejné sítě může být tato energie ukládána do akumulátoru, což umožňuje jejímu pozdějšímu dodání v okamžiku, kdy jsou výkupní ceny nejvyšší, a tím maximalizovat ekonomickou výhodnost provozu solární elektrárny [3].



Obr. 2. Typická struktura solární elektrárny [3].

3.1.2 Výkon solárního modulu

Výkon fotovoltaického modulu je měřen za následujících podmínek:

- Hodnota slunečního záření: 1000 W/m²
- Teplota solárního modulu: 25 °C
- Standardní sluneční spektrum: AM 1.5

Maximální výkon solárního modulu za těchto podmínek je označována jako jmenovitý výkon (nebo nominální výkon) modulu. Tento výkon se uvádí v jednotkách Watt-Peak (Wp) a popisuje maximální výkon modulu za optimálních podmínek [2].

Efektivita solárního modulu, který přetváří dopadající sluneční energii na elektrickou energii, je určena jeho účinností. Účinnost η se vypočítává jako poměr jmenovitého výkonu P_n k dopadajícímu výkonu slunečního záření P_{sol} (Rovnice 1). Obvykle se udává v procentech, přičemž u křemíkových solárních modulů se běžně dosahuje hodnot v rozmezí 13–20 % [2].

$$\eta_{Modulu}(\%) = \left(\frac{P_n}{P_{sol}} \right) * 100$$

Rovnice 1. Výpočet účinnosti [2].

3.2 Dopadající sluneční záření

Sluneční záření, které dopadá na solární modul, se skládá ze tří složek (Obr. 3): přímého záření přicházejícího přímo ze Slunce, difúzního záření rozptýleného v atmosféře a odraženého záření od zemského povrchu. Aby bylo možné zachytit co největší množství tohoto záření, je důležité správně nastavit azimut modulů, což je úhel orientace vůči světovým stranám. Na severní polokouli je ideální orientace na jih, což zajišťuje maximální příjem slunečního světla po celý rok (Obr. 4). Dalším klíčovým faktorem je úhel náklonu β , který optimalizuje příjem přímého slunečního záření. Správná kombinace úhlu náklonu a azimutu zvyšuje výkon solárního modulu, protože optimalizuje příjem všech tří složek slunečního záření. Rovnice 2 ukazuje složky celkového slunečního záření dopadající na solární modul [2].

$$E_{Celk} = E_{Přímé} + E_{Difúzní} + E_{Odražené}$$

Rovnice 2. Složky celkového slunečního záření [2].


Kde:

E_{celk} je celkové sluneční záření dopadající na povrch modulu (W/m^2).


$E_{přímé}$ je přímé sluneční záření (W/m^2), které dopadá přímo na modul.

$E_{Difúzní}$ je difúzní složka slunečního záření (W/m^2), která je rozptýlena atmosférou a dopadá na modul z různých směrů.

$E_{Odražené}$ je odražená složka slunečního záření (W/m^2), která je odražena od okolních povrchů (např. země, budovy).



Obr. 3. Jednotlivé složky slunečního záření dopadající na solární modul [2].



Obr. 4. Úhel azimutu slunce se mění v závislosti na geografické poloze [4].

4 Faktory ovlivňující výkon FVE

Teoretický výpočet výkonu solárního modulu za předpokladu, že je známa hodnota slunečního záření dopadajícího na modul se vypočítá pomocí Rovnice 3 [5].

$$P_{Teor} = E_{Celk} * \eta * S * \cos \beta$$

Rovnice 3. Výpočet výkonu solárního modulu [5].

Kde:

P_{Teor} je výkon solárního modulu (W)

E_{Celk} je celkové sluneční záření (W/m²), které dopadá přímo na modul.

η je účinnost solárního modulu (-)

S je plocha solárního modulu (m²)

β je úhel sklonu solárního modulu vůči horizontu (°)

V praxi ovlivňuje výkon fotovoltaických systémů řada meteorologických (např. oblačnost) a konstrukčních faktorů (např. orientace panelů, kvalita materiálů, stínění), které vedou k nevyhnutelným ztrátám i přes 20 %.

4.1 Meteorologické faktory

4.1.1 Intenzita slunečního záření a úhel dopadu

Množství slunečního záření a jeho úhel dopadu na plochu solárního modulu jsou klíčovými faktory ovlivňujícími výkon. Cílem je, aby solární modul zachytil co nejvíce slunečního záření a maximalizoval tak produkci elektrické energie [6].

Nejvyšší efektivita se dosahuje, když sluneční paprsky dopadají na povrch modulu pod úhlem 90 stupňů. V běžných podmínkách však bývá úhel dopadu často menší, což způsobuje snížení intenzity záření, které solární modul absorbuje. Například při úhlu dopadu 45 stupňů je intenzita slunečního záření přibližně o 30 % nižší než při kolmém dopadu. Tento úhel dopadu slunečního záření se mění v závislosti na geografické poloze, ročním období a denní době. Úhel sklonu solárních modulů by měl být optimálně dynamicky přizpůsobován těmto faktorům, aby bylo dosaženo co nejvyšší účinnosti [6–9].

4.1.2 Teplota

Paradoxně, i když vyšší sluneční intenzita obvykle umožňuje fotovoltaickým modulům generovat více elektrické energie, může také vést k jejich většímu ohřevu, což

může snížit jejich výkon. Významná část absorbovaného slunečního záření se přeměňuje na teplo a s rostoucí teplotou fotovoltaického modulu klesá jeho účinnost a výkon [4,10–12].

Fotovoltaické moduly obvykle dosahují maximální účinnosti při teplotách mezi 15 °C a 35 °C. Výrobci v technických listech uvádějí teplotní koeficient, který ukazuje, o kolik procent klesne účinnost modulu na každý stupeň, o který teplota překročí 25 °C. Tento koeficient se obvykle pohybuje kolem -0,3 %. V důsledku toho mohou vysoké teploty snížit výkon solárního panelu o 10 % až 25 % [4,9–11].

Extrémní teploty mohou navíc poškodit materiály použité ve fotovoltaických modulech, což zkracuje jejich životnost a zvyšuje riziko poruch. Proto je klíčové věnovat pozornost efektivnímu chlazení těchto modulů, aby se minimalizovaly teplotní ztráty a zajistila se dlouhá životnost celého fotovoltaického systému [10–12].

4.1.3 Odrazivost

Odrazivost povrchu fotovoltaických modulů způsobuje značné ztráty dopadajícího slunečního záření, protože část tohoto záření se odráží dříve, než je absorbována polovodičem. Bez jakýchkoli úprav může křemíkový povrch odrážet až 35 % slunečního záření[2].

Tento problém lze řešit pomocí antireflexní vrstvy a texturování povrchu modulů (například leptáním). Tyto metody samostatně snižují průměrnou odrazivost na přibližně 10 %. V kombinaci mohou snížit odrazivost fotovoltaických modulů až na pouhé 3 % [2].

4.1.4 Stínění

I malé změny ve stínění, například vlivem mraků nebo okolních objektů, mohou mít významný dopad na výkonnost fotovoltaického modulu. Jednotlivé fotovoltaické články se běžně zapojují do série, což má za následek, že stínění jednoho článku může ovlivnit výkon celého modulu. Obecně platí, že stíněné moduly dosahují zhruba o polovinu nižšího výkonu než při plném slunečním osvětlení [4,11–14].

Stínění fotovoltaických modulů je zásadním faktorem, který ovlivňuje jejich účinnost a výkon. Dělí se na dva hlavní typy: dynamické a statické stínění [13].

Dynamické stínění vzniká působením pohyblivých objektů, jako jsou mraky, které mohou měnit polohu a velikost stínu na článcích, což způsobuje významné kolísání výkonu [7,13].

Statické stínění je způsobeno trvalými objekty v okolí a dělí se na dva hlavní typy. Prvním je stínění způsobené okolními objekty, jako jsou budovy, stromy nebo hory. Tento typ stínění může být buď úplný, kdy je fotovoltaický panel zcela zakryt, nebo částečný, kdy je stíněna pouze část panelu. Oba případy mohou vést k výraznému poklesu výkonu fotovoltaické elektrárny. Druhým typem je stínění způsobené řadou panelů, kdy jsou moduly umístěny příliš blízko sebe. V tomto případě dochází k vzájemnému stínění panelů, což může opět vést k poklesu výkonu celé elektrárny [6,12,13].

4.1.5 Znečištění

Znečištění solárních panelů může výrazně ovlivnit jejich schopnost absorbovat sluneční záření a přeměňovat ho na elektrickou energii. Hromadění nečistot, jako jsou prach, písek, ptací trus, listí nebo sníh, snižuje množství slunečního záření dopadajícího na plochu fotovoltaických modulů a může vést k výrazným ztrátám výkonu [6,11,12,15].

Podle studií mohou znečištěné moduly ztratit až 5 % ze svého výkonu již během pouhých tří měsíců. Proto je nutné panely pravidelně čistit. Většina znečištění se hromadí v zimě, proto je jaro ideálním obdobím pro roční čištění panelů. Optimální frekvence čištění se však odvíjí od místních podmínek, jako je úroveň znečištění vzduchu, četnost výskytu bouřek a dalších faktorů [6,11,15].

4.2 Konstrukční faktory

4.2.1 Degradace

Fotovoltaické moduly postupně degradují, což vede ke snižování jejich výkonu. Výzkumy ukazují, že průměrná roční ztráta výkonu těchto modulů činí přibližně 1 %. Degradace je primárně způsobena vlivy prostředí, ve kterém jsou moduly instalovány. Extrémní povětrnostní podmínky, jako je krupobití, silný vítr nebo sníh, mohou přispět k fyzickému poškození modulů – například způsobením mikrotrhlin nebo narušením těsnění, které chrání moduly před degradací. UV záření navíc postupně rozkládá některé komponenty modulů. Tepelné cykly, tedy roztažení a smršťování materiálů v důsledku denních a sezónních změn teplot, také postupně zhoršují stav fotovoltaických modulů. Degradace fotovoltaických modulů je nevyhnutelným procesem, který je ovlivněn řadou faktorů. Je důležité věnovat pozornost kvalitě instalace a pravidelné údržbě, aby se minimalizovaly negativní dopady těchto vlivů [2,4,7,11,16].

4.2.2 Invertory

Invertory převádějí stejnosměrné napětí generované fotovoltaickými moduly na střídavé napětí používané v elektrických sítích. Při této přeměně dochází k energetickým ztrátám, zejména ve formě tepla a energie potřebné pro samotný provoz měniče. Tyto ztráty se liší v závislosti na zatížení invertoru – při nižší zátěži jsou ztráty obvykle vyšší. Výše těchto ztrát je dána účinností invertoru. Kvalitní invertory dosahují účinnosti v rozmezí 95 až 98 %, což znamená nižší ztráty výkonu fotovoltaického systému [4,6,7,17,18].

4.2.3 Odpor ve vodičích

Ztráty ve vodičích jsou běžným jevem ve fotovoltaických systémech, které snižují jejich celkovou účinnost. Tyto ztráty vznikají v důsledku odporu vodičů, které vedou napětí z fotovoltaických modulů do invertorů nebo distribuční sítě. Míra těchto ztrát je ovlivněna odporem vodiče, který závisí na jeho délce, průřezu a materiálu. Měď, například, má nižší odpor než hliník, a proto se často používá v instalacích s menšími ztrátami [18–20].

Ztráty ve výkonu jsou úměrné druhé mocnině proudu a odporu vodiče, což znamená, že vyšší proudy a delší vedení vedou k větším ztrátám. Pro minimalizaci těchto ztrát je klíčové používat vodiče s větším průřezem, což snižuje jejich odpor, a umístit invertory co nejblíže k fotovoltaickým panelům, aby se omezila délka vedení [18–20].

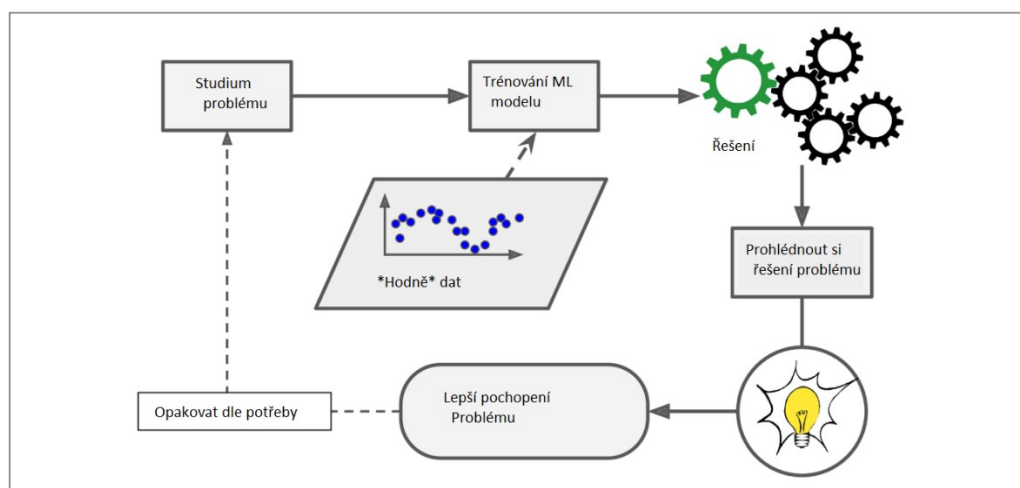
Dalšími faktory, které ovlivňují ztráty, jsou teplota vodičů a optimalizace napětí v systému. Vyšší teplota zvyšuje odpor vodičů, což způsobuje větší ztráty. Standardně se ztráta projevuje mezi 1 až 2 %. Optimalizace těchto parametrů je důležitá pro efektivní provoz fotovoltaických systémů [18,20].

5 Strojové učení

Strojové učení je podmnožinou umělé inteligence (AI), která převádí data do číselné podoby a hledá v nich vzory a souvislosti. Používá se k řešení komplexních úloh, kde není možné snadno definovat všechna pravidla nebo neexistuje známý algoritmus pro jejich řešení. Modely strojového učení se trénují na tzv. trénovacích datech, aby na jejich základě dokázaly predikovat nová, dosud neviděná data. Mezi běžně používané modely patří rozhodovací stromy (Decision Trees), metoda podpůrných vektorů (Support Vector Machine, SVM) nebo neuronové sítě [21].

Strojové učení nachází uplatnění v mnoha oblastech, kde je potřeba analyzovat velké objemy dat a identifikovat v nich vzory. V oblasti zpracování textu se využívá například pro filtrování spamu, kdy na základě vzorových e-mailů označených uživatelem jako spam nebo ham klasifikuje nové zprávy. V průmyslu se používá k detekci vad na výrobních linkách, v medicíně k analýze snímků pro diagnostiku nemocí. Uplatňuje se také v predikci časových řad, například při modelování výkonu fotovoltaických elektráren na základě historických měření a meteorologických dat [22].

Strojové učení může také přispět k objevování nových poznatků – například spamový filtr může identifikovat klíčová slova nejčastěji spojovaná se spamem, což pomáhá při vývoji ochranných mechanismů (viz Obr. 5) [22].



Obr. 5. Strojové učení může přispět k objevování nových poznatků [22].

5.1 Typy strojového učení


Strojové učení se dělí na učení s učitelem, učení bez učitele a učení s posilováním, přičemž každý přístup využívá odlišný způsob zpracování dat. Následující kapitoly je podrobněji rozebírají [22].

5.1.1 Učení s učitelem (supervised learning)


Při učení s učitelem obsahuje trénovací sada vstupy s přiřazenými výstupy, tzv. štítky (labels) (viz. Obr. 6). Tento přístup se nejčastěji využívá pro klasifikační a regresní úlohy.

Klasifikační úlohy spočívají v přiřazení vstupních dat do předem definovaných kategorií. Typickým příkladem je spamový filtr, který se učí rozlišovat mezi e-maily označenými jako spam nebo ham (viz Obr. 6). Model je trénován na velkém množství vzorových e-mailů a jeho cílem je správně klasifikovat nové zprávy [22].

Regresní úlohy se zaměřují na predikci spojitých číselných hodnot na základě vstupních rysů (features). Příkladem je predikce výkonu fotovoltaické elektrárny, kde model využívá meteorologická data, jako je intenzita slunečního záření a okolní teplota, k odhadu budoucí výroby elektrické energie (viz. Obr. 7) [22].



Obr. 6. Označená tréninková sada pro klasifikaci spamu (příklad učení s učitelem) [22].




Obr. 7. Regresní úloha, predikce hodnoty na základě rysu [22].

5.1.2 Učení bez učitele (unsupervised learning)

Učení bez učitele je typ strojového učení, při kterém jsou trénovací data bez štítků (labels). To znamená, že systém nemá k dispozici žádné předem definované kategorie nebo správné odpovědi. Cílem algoritmu je odhalit skryté struktury, vzory nebo vztahy v datech. Používá se především při práci s rozsáhlými a nestructurovanými daty, kde umožňuje identifikovat souvislosti a získat nové poznatky [22].

Mezi nejčastější aplikace učení bez učitele patří shlukování dat (clustering, viz. Obr. 8), při kterém algoritmus seskupuje podobné datové body na základě jejich vlastností. Například v analýze uživatelského chování může shlukování odhalit skupiny zákazníků s podobnými nákupními vzory, což umožňuje cílenější marketing [22].

Další využití zahrnuje metody pro snížení dimenzionality, detekci anomálií či učení asociačních pravidel, které nacházejí uplatnění v oblastech, jako jsou zpracování dat, bezpečnostní analýzy nebo maloobchod [22].

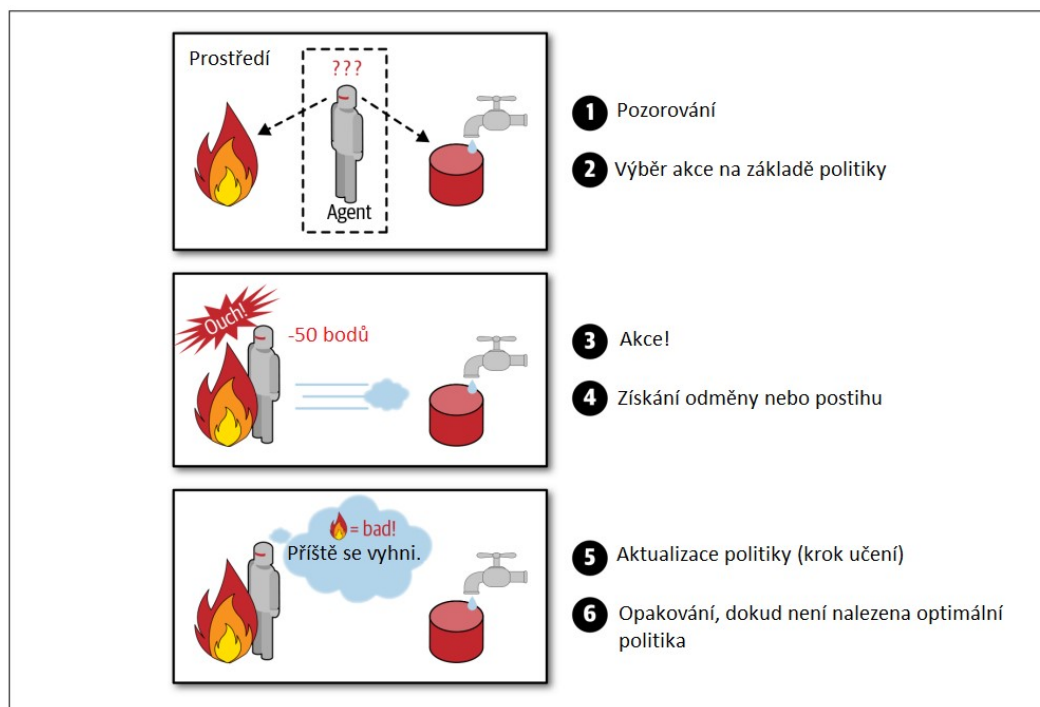


Obr. 8. Shlukování v učení bez učitele [22].

5.1.3 Učení s posilováním (Reinforcement Learning)

Učení posilováním (Obr. 9) představuje odlišný přístup ke strojovému učení. Systém, označovaný jako agent, interaguje se svým prostředím (environment) tím, že provádí akce a na základě jejich výsledků získává odměny (rewards) nebo postihy (penalties). Cílem agenta je naučit se optimální strategii, tzv. politiku (policy), která definuje, jaké akce by měl agent zvolit v různých situacích, aby maximalizoval kumulovanou odměnu v čase [22].

Proces učení probíhá metodou pokus–omyl, kdy agent testuje různé přístupy a na základě zpětné vazby upravuje své chování. Učení s posilováním se využívá v autonomním řízení, kde umožňuje reagovat na dopravní situace, v energetice při řízení spotřeby nebo ve videohrách, kde agenti trénují strategie pro dosažení lepších výsledků [22].



Obr. 9. Učení posilováním (Reinforcement Learning) [22].

5.2 Hlavní výzvy strojového učení

Úspěšnost modelu závisí na dostupnosti kvalitních a dostatečně reprezentativních dat. Mezi hlavní problémy patří nedostatek trénovacích dat, šum a chybějící hodnoty, redundance či nerelevantní rysy, které mohou negativně ovlivnit výkon modelu. Tyto výzvy jsou podrobně rozebrány v následujících podkapitolách [21,22].

5.2.1 Dostatek a kvalita trénovacích dat

Modely strojového učení vyžadují rozsáhlé a kvalitní datové sady, které musí odpovídat reálným podmínkám. Pokud jsou data nedostatečná, nereprezentativní nebo zkreslená, model nemusí dobře generalizovat a může vykazovat chyby [21,22].

5.2.2 Šum a chybějící hodnoty

Špatná kvalita dat (chyby v měření, odlehlé hodnoty, šum) může negativně ovlivnit přesnost modelu. Často je nutné provést předzpracování, jako je odstranění odlehlých hodnot nebo doplnění chybějících údajů [22].

5.2.3 Redundance a nerelevantní vlastnosti

Duplicitní nebo nadbytečné informace mohou zkreslit výsledky modelu. Stejně tak příliš mnoho nerelevantních rysů může snížit jeho výkon. K omezení těchto problémů slouží inženýrství rysů (feature engineering), které zahrnuje nejen výběr relevantních rysů, ale i jejich kombinaci a transformaci pro lepší reprezentaci vstupních dat [22].

5.2.4 Inženýrství rysů (Feature Engineering)

Inženýrství rysů je proces vytváření nových atributů nebo transformace stávajících s cílem zlepšit schopnost modelu identifikovat vzory v datech. K efektivním technikám patří kombinace proměnných k odhalení skrytých souvislostí, redukce dimenzionality pro odstranění nadbytečných rysů a doménově specifické rysy, které reflektují odborné znalosti z dané problematiky. Správně navržené rysy mohou výrazně zvýšit přesnost predikcí a snížit nároky na trénovací data [22].

5.3 Normalizace rysů (Feature Scaling)

Algoritmy strojového učení, zejména neuronové sítě, vykazují lepší výsledky pokud jsou vstupní proměnné ve srovnatelných rozsazích. Nejlepších výsledků je dosaženo, pokud se numerické hodnoty pohybují v rozmezí od -1 do 1 s průměrnou hodnotou blízkou nule [22]. Pro normalizaci rysů se nejčastěji používají metody uvedené v následujících podkapitolách.

5.3.1 Min-max škálování (normalizace):

Min-max normalizace nejčastěji převádí hodnoty do intervalu $<0; 1>$ odečtením minimální hodnoty a dělením rozdílem mezi maximem a minimem. Výpočet je dán podle Rovnice 4.

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Rovnice 4. Min-max škálování [22].

Kde:

- x_{norm} – normalizovaná hodnota
- x – původní hodnota
- x_{min} – nejmenší hodnota v datové sadě
- x_{max} – největší hodnota v datové sadě

5.3.2 Standardizace (z-skórová normalizace):

Převádí hodnoty na rozdělení s nulovým průměrem a jednotkovou směrodatnou odchylkou. Toho je dosaženo odečtením průměru a následným vydělením směrodatnou odchylkou. Na rozdíl od min-max škálování není standardizace vázána na pevný rozsah a je odolnější vůči odlehlým hodnotám. Výpočet je dán podle Rovnice 5 [22].

$$z = \frac{x - \mu}{\sigma}$$

Rovnice 5. Standardizace[22].

kde:

- z – standardizovaná hodnota (z-skóre)
- x – původní hodnota
- μ – průměrná hodnota datové sady
- σ je směrodatná odchylka datové sady.

Správně provedená příprava dat je základním předpokladem pro dosažení vysoké přesnosti modelu a jeho schopnosti generalizovat na nová data[22].

5.3.3 Yeo-Johnsonova transformace

Yeo-Johnsonova transformace slouží k nelineární úpravě dat tak, aby se co nejvíce přiblížila normálnímu rozdělení, přičemž zachovává jejich pořadí v datové sadě. Výpočet je dán podle Rovnice 6 [23].

$$\psi(\lambda, x) = \begin{cases} \frac{(x+1)^\lambda - 1}{\lambda}, & \text{pokud } \lambda \neq 0, x \geq 0 \\ \log(x+1), & \text{pokud } \lambda = 0, x \geq 0 \\ \frac{-[(1-x)^{2-\lambda} - 1]}{2-\lambda}, & \text{pokud } \lambda \neq 2, x < 0 \\ -\log(1-x), & \text{pokud } \lambda = 2, x < 0 \end{cases}$$

Rovnice 6. Yeo-Johnsonova transformace [23].

Kde:

- $\psi(\lambda, x)$ – transformovaná hodnota
- λ – transformační parametr, určovaný empiricky s cílem maximalizovat normalitu dat
- x – vstupní hodnota před transformací

5.4 Dávkové učení (Batch Learning) a kontinuální učení (Online Learning)

Dalším kritériem pro klasifikaci modelů strojového učení je jejich schopnost učit se z nově přichozích dat. Existují dva základní přístupy: dávkové učení (batch learning) a kontinuální učení (online learning) [22].

5.4.1 Dávkové učení (batch learning)

Dávkové učení (Batch learning) je přístup, při kterém je model trénován na celé dostupné datové množině najednou. Po dokončení trénovací fáze je model nasazen do provozu, kde aplikuje naučené znalosti bez další schopnosti se sám adaptovat. Tento způsob učení se označuje také jako offline učení [22].

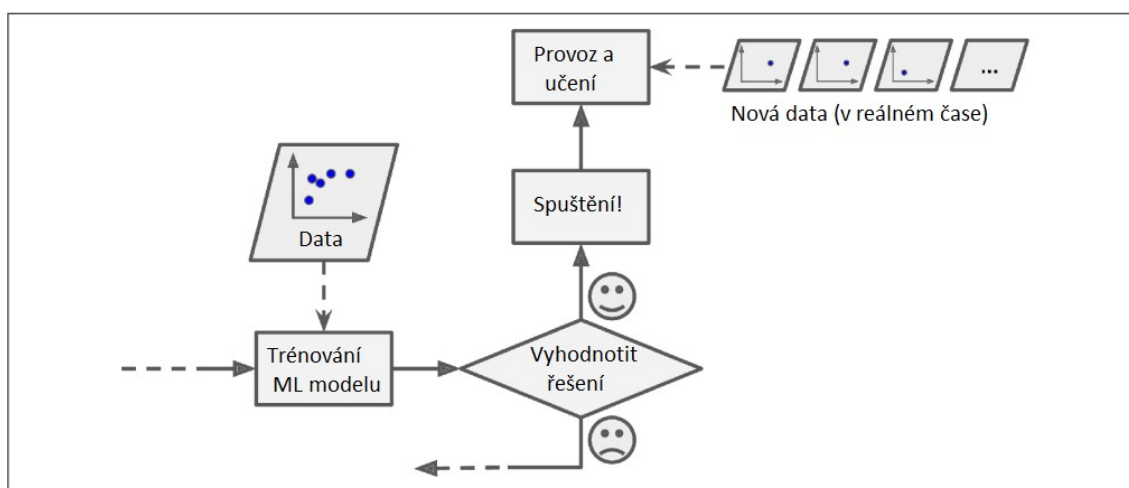
Pokud je potřeba model aktualizovat o nové informace (například o novém typu spamu), je nutné jej přeškolenit od začátku na kompletní datové množině – zahrnující jak nová, tak původní data. Tento proces je náročný na výpočetní zdroje a může trvat i několik hodin, což omezuje frekvenci aktualizací na denní nebo týdenní intervaly [22].

Nevýhodou dávkového učení je omezená schopnost rychle reagovat na dynamické změny dat, což jej činí méně vhodným pro aplikace vyžadující reakce v reálném čase

(například predikce cen akcií). Na druhou stranu je tento přístup stabilní, snadno automatizovatelný a méně citlivý na šum v datech [22].

5.4.2 Kontinuální učení (online Learning)

Dalším přístupem k trénování modelů je kontinuální učení (online learning), který na rozdíl od dávkového učení umožňuje modelu průběžně se učit z nově příchozích dat. Model se aktualizuje po každém novém datovém vzorku nebo po malé dávce dat (tzv. mini-batch) viz. Obr. 10. Tento přístup je vhodný pro systémy, které musí rychle reagovat na změny, například při predikci výkonu fotovoltaických elektráren, kde dochází k častým výkyvům vlivem změn počasí nebo degradace účinnosti panelů [22].



Obr. 10. Model je natrénován a nasazen do produkce, kde se průběžně učí z nových dat [22].

Online learning je také efektivní v prostředích s omezenými výpočetními zdroji, protože model po zpracování nových dat již nepotřebuje tato data uchovávat. To snižuje nároky na úložiště. Navíc umožňuje trénování modelu na velkých datových sadách, které se nevejdou do úložiště jednoho zařízení, což se označuje jako out-of-core learning [22].

Důležitým parametrem online learningu je rychlost učení (learning rate), která určuje, jak rychle se model přizpůsobuje novým datům. Příliš vysoká hodnota může vést k rychlému „zapomínání“ starších informací, zatímco příliš nízká hodnota zpomaluje adaptaci na nové podmínky [22].

Jednou z hlavních výzev kontinuálního učení je zajištění kvality vstupních dat. Chybná nebo záměrně manipulovaná data mohou negativně ovlivnit výkonnost modelu. Proto je důležité systém pravidelně monitorovat, detekovat anomálie a v případě potřeby obnovit model do předchozí funkční verze [22].

5.5 Rozdělení dat pro trénování a testování modelu

Pro zjištění schopnosti modelu generalizovat na nová data se datová sada obvykle rozděluje na trénovací, validační a testovací sadu [22].

5.5.1 Trénovací sada

Trénovací sada (training set) slouží k učení modelu, kdy se na jejím základě model přizpůsobuje vstupním datům. Obvykle se používá 60 % dat pro trénování, ale tento poměr může být upraven v závislosti na velikosti datové sady [22].

5.5.2 Validací sada

Validační sada (validation set) slouží k ladění modelu a výběru optimálních hyperparametrů. Standardní rozdělení zahrnuje 20 % dat pro validační sadu, ale stejně jako u trénovací sady závisí optimální poměr na celkovém objemu dat [22].

5.5.3 Testovací sada

Testovací sada (test set) se používá pro finální hodnocení modelu na datech, která nebyla použita během trénování ani ladění. Chybovost modelu na testovacích datech se označuje jako chyba generalizace (generalization error) a udává, jak přesně model dokáže pracovat s dosud neviděnými daty [22].

Obvykle se testovací sada tvoří 20 % celkových dat, ale u velmi rozsáhlých datových sad (například s 10 miliony vzorků) může být dostačující i menší podíl, například 1 %, což stále představuje dostatek dat pro přesný odhad chyby generalizace [22].

5.6 Ztrátové funkce

Ztrátová funkce (loss function, objective function) se používá k hodnocení přesnosti predikcí modelu. Cílem je minimalizovat její hodnotu během trénování modelu pomocí optimalizačních technik. U regresních úloh, kde model predikuje spojité numerické hodnoty, se přesnost určuje rozdílem mezi skutečnými a predikovanými hodnotami. Pokud data neobsahují výrazné odlehlé hodnoty, nejčastěji se používají ztrátové funkce Mean Squared Error (MSE) nebo Root Mean Squared Error (RMSE). Naopak, pokud se v datech vyskytují výrazné odlehlé hodnoty, preferuje se použití ztrátové funkce Mean Absolute Error (MAE), která je vůči nim méně citlivá [21,22].

5.6.1 Střední kvadratická chyba – Mean Squared Error (MSE):

Střední kvadratická chyba (MSE, Mean square error) se vypočítá jako průměr čtvercových rozdílů mezi skutečnými a predikovanými hodnotami. Umocnění těchto rozdílů způsobuje, že větší chyby v predikci mají výraznější dopad na celkovou hodnotu chyby. V praxi je tato funkce preferovanější volbou před RMSE, protože nabízí snadnější derivaci, kterou využívají optimalizační algoritmy. *Rovnice 7* ukazuje její výpočet. [22]

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}_{(i)} - y_{(i)})^2$$

Rovnice 7. Ztrátová funkce MSE [22].

Kde:

- m – počet prvků v datové sadě
- $\hat{y}$ – predikovaná hodnota pro daný vstup
- y – skutečná hodnota pro daný vstup

5.6.2 Střední kvadratická odchylka – Root mean square error (RMSE):

Střední kvadratická odchylka (RMSE, Root mean square error) vznikne odmocněním hodnoty MSE. Stejně jako MSE i RMSE je citlivá na velké chyby v predikci, ale její výhodou je, že jednotky výsledku odpovídají jednotkám predikovaných hodnot. *Rovnice 8* ukazuje její výpočet [22].

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (\hat{y}_{(i)} - y_{(i)})^2}$$

Rovnice 8. Ztrátová funkce RMSE [22].

Kde:

- m – počet prvků v datové sadě
- $\hat{y}$ – predikovaná hodnota pro daný vstup
- y – skutečná hodnota pro daný vstup

5.6.3 Střední absolutní chyba – Mean absolute error (MAE):

Střední absolutní chyba (MAE, Mean Absolute Error) se vypočítá jako průměr absolutních rozdílů mezi skutečnými a predikovanými hodnotami. Na rozdíl od MSE není citlivá na velké chyby v predikci, protože neumocňuje tyto rozdíly. Rovnice 9 představuje její výpočet [22].

$$MAE = \frac{1}{m} \sum_{i=1}^m |\hat{y}_{(i)} - y_{(i)}|$$

Rovnice 9. Ztrátová funkce MAE [22].

Kde:

- m – počet prvků v datové sadě
- $\hat{y}$ – predikovaná hodnota pro daný vstup
- y – skutečná hodnota pro daný vstup

5.7 Metriky pro hodnocení modelu

Kromě již zmíněných ztrátových funkcí (MSE, RMSE, MAE), které lze využít i k hodnocení modelu, existují další metriky poskytující lepší přehled o přesnosti predikcí vůči skutečným hodnotám a umožňující srovnání různých modelů. Každá metrika nabízí jiný pohled na přesnost predikcí. Pro regresní modely se kromě zmíněných metrik často používají také: střední absolutní procentní chyba (Mean Absolute Percentage Error, MAPE), symetrická střední absolutní procentní chyba (symmetric Mean Absolute Percentage Error, sMAPE), koeficient determinace (R^2) a Průměrná systematická odchylka – Mean Bias Error (MBE) [24].

5.7.1 Střední absolutní procentní chyba – Mean Absolute Percentage Error (MAPE)

Střední absolutní procentní chyba (MAPE) vyjadřuje průměrnou procentuální odchylku predikovaných hodnot od skutečných hodnot. Tato metrika je intuitivní a snadno interpretovatelná, protože udává průměrnou chybu v procentech, což umožňuje jednoduché srovnání různých modelů [24].

Nevýhodou MAPE je její citlivost na skutečné hodnoty blízké nule, což může vést k extrémně vysokým a zkresleným výsledkům. V případech, kdy se v datech vyskytují nulové hodnoty, není MAPE definovaná. Dalším omezením je její sklon k nadhodnocování

chyb u modelů, jejichž predikce systematicky podhodnocují skutečné hodnoty. Rovnice 10 zobrazuje její výpočet [25].

$$MAPE = \frac{100}{m} \sum_{i=1}^m \frac{|\hat{y}_{(i)} - y_{(i)}|}{y_{(i)}}$$

Rovnice 10. Střední absolutní procentní chyba (MAPE) [25].

Kde:

- m – počet prvků v datové sadě
- $\hat{y}$ – predikovaná hodnota pro daný vstup
- y – skutečná hodnota pro daný vstup

5.7.2 Symetrická střední absolutní procentní chyba – symmetric Mean Absolute Percentage Error (sMAPE)

Symetrická střední absolutní procentní chyba (sMAPE) představuje upravenou verzi MAPE, která zmírňuje některé její nevýhody, zejména zkreslení při skutečných hodnotách blízkých nule. Zatímco MAPE normalizuje chybu predikce pouze podle skutečné hodnoty, sMAPE chybu normalizuje vzhledem k průměru skutečné a predikované hodnoty, čímž omezuje extrémní hodnoty chyby v případech, kdy jsou skutečné hodnoty velmi malé [25].

Existuje několik variant sMAPE, které se mohou lišit například způsobem zacházení s nulovými hodnotami nebo přítomností další normalizace. Rovnice 11 ukazuje jednu z běžně používaných definic výpočtu, jejíž rozsah je od 0 % do 100 %, přičemž nižší hodnoty indikují vyšší přesnost [25].

$$sMAPE = \frac{100}{m} \sum_{i=1}^m \frac{|\hat{y}_{(i)} - y_{(i)}|}{(|\hat{y}_{(i)}| + |y_{(i)}|)/2}$$

Rovnice 11. Symetrická střední absolutní procentní chyba [25].

Kde:

- m – počet prvků v datové sadě
- $\hat{y}$ – predikovaná hodnota pro daný vstup
- y – skutečná hodnota pro daný vstup

5.7.3 Koeficient determinace – R square (R^2)

Koeficient determinace (R^2) je statistická metrika, která vyjadřuje, jak velkou část variability závislé proměnné lze vysvětlit pomocí nezávislých proměnných. Udává míru, do jaké míry predikované hodnoty z modelu odpovídají variabilitě skutečných dat. Nehodnotí však přesnost jednotlivých predikcí, tedy neříká, jak blízko jsou predikované hodnoty skutečným hodnotám [24,26].

Koeficient determinace obvykle nabývá hodnot v intervalu $\langle 0,1 \rangle$, ale v některých případech může být záporný. Hodnota blízka 1 znamená, že model dobře vysvětluje variabilitu závislé proměnné. Naopak hodnota blízka 0 naznačuje, že model není schopen zachytit vztah mezi nezávislými a závislou proměnnou lépe než pouhé použití průměrné hodnoty závislé proměnné. V případě záporné hodnoty model predikuje hůře než použití průměrné hodnoty závislé proměnné. *Rovnice 12* uvádí jeho výpočet [26,27].

$$R^2 = 1 - \frac{\sum_{i=1}^m (y_{(i)} - \hat{y}_{(i)})^2}{\sum_{i=1}^m (y_{(i)} - \bar{y})^2}$$

Rovnice 12. Koeficient determinace [26].

Kde:

- m – počet prvků v datové sadě
- $\hat{y}$ – predikovaná hodnota pro daný vstup
- y – skutečná hodnota pro daný vstup
- $\bar{y}$ – průměrná skutečná hodnota

5.7.4 Průměrná systematická odchylka – Mean Bias Error (MBE)

Průměrná systematická odchylka (MBE) vyjadřuje průměrný rozdíl mezi predikovanými a skutečnými hodnotami. Tato metrika se udává ve stejných jednotkách jako jsou predikované a skutečné hodnoty a poskytuje informaci o tom, zda model systematicky nadhodnocuje nebo podhodnocuje predikce ve srovnání se skutečnými hodnotami [28].

Pozitivní hodnota MBE značí, že model v průměru nadhodnocuje predikce oproti skutečným hodnotám, zatímco záporná hodnota indikuje, že model predikce systematicky podhodnocuje. Ideální hodnota MBE je 0, což znamená, že model nevykazuje

systematickou chybu a jeho predikce nejsou zkreslené v žádném směru. MBE lze vypočítat podle Rovnice 13 [28].

$$MBE = \frac{1}{m} \sum_{i=1}^m \hat{y}_{(i)} - y_{(i)}$$

Rovnice 13. Průměrná systematická odchylka [28].

Kde:

- m – počet prvků v datové sadě
- $\hat{y}$ – predikovaná hodnota pro daný vstup
- y – skutečná hodnota pro daný vstup


5.8 Přeučení a podučení modelu (overfitting, underfitting)

Modely strojového učení mohou trpět dvěma základními problémy: přeučením (overfitting) a podučením (underfitting). Přeučení nastává, když model dosahuje vynikajících výsledků na trénovacích datech, ale selhává při generalizaci na nová, neznámá data. Tento problém vzniká, pokud je model příliš složitý a učí se nejen skutečné vzory, ale i šum a nerelevantní detaily, což vede ke snížení jeho predikční schopnosti. V důsledku toho může model identifikovat náhodné odchylky v trénovacích datech jako obecně platné vzory, které se však v nových datech nevyskytují [22].

Naopak podučení nastává, pokud je model příliš jednoduchý na to, aby zachytil základní strukturu dat. Model s nízkou složitostí nedokáže správně identifikovat vztahy mezi vstupními rysy a výstupy, což vede k nízké přesnosti predikcí i na trénovacích datech. Na počátku trénování jsou optimalizace a generalizace vzájemně provázané – se snižující se hodnotou ztrátové funkce na trénovacích datech klesá i její hodnota na validačních datech. V této fázi je model stále podučený, protože ještě nezachytil všechny relevantní vzory v datech. Jakmile však trénování pokračuje, může model začít přizpůsobovat své predikce specifikům trénovacích dat do té míry, že jeho výkonnost na validačních datech začne klesat, čímž dochází k přeučení viz Obr. 11 [21].

Riziko přeučení lze snížit několika způsoby, například zjednodušením modelu, zvýšením množství trénovacích dat či redukcí šumu v datech, tedy odstraněním odlehlých hodnot a chyb. Další možností je využití regularizačních metod, které brání modelu v nadměrném přizpůsobení trénovacím datům, například dropout (náhodné vynechávání neuronů během trénování) [21,22].

Při podučení lze naopak zlepšit výkon modelu volbou složitější architektury, vylepšením vstupních rysů (feature engineering) nebo snížením restrikcí, například omezením regularizace. Pokud model není dostatečně natrénovaný, může pomoci prodloužení trénovacího procesu, dokud nezachytí všechny relevantní vzory v datech, aniž by došlo k přeučení [21,22].



Obr. 11. Průběh procesu učení.

6 Hluboké učení zaměřené na predikci výkonu FVE


Hluboké učení (deep learning) je specifickou podmnožinou strojového učení, která se zaměřuje na modelování složitých nelineárních vztahů v datech pomocí neuronových sítí. Název „hluboké“ odkazuje na architekturu sítě zahrnující více skrytých vrstev (tzv. hidden layers). Tyto vrstvy umožňují modelu extrahovat hierarchicky strukturované vzory z dat – od jednoduchých rysů na nižších vrstvách až po složitější abstrakce na vyšších vrstvách [21].

Proces učení (viz. Obr. 12) probíhá iterativně prostřednictvím optimalizace vah neuronové sítě na základě zpětnovazebního mechanismu ztrátové funkce (loss function). Tato funkce kvantifikuje rozdíl mezi predikovanými a skutečnými hodnotami, přičemž její minimalizaci zajišťuje algoritmus zpětného šíření chyby (backpropagation) v kombinaci s optimalizačními technikami, jako je Adam nebo SGD. Efektivní trénování hlubokých neuronových sítí vyžaduje značný výpočetní výkon, často s využitím grafických procesorů (GPU) [21].

Vzhledem k experimentální povaze hlubokého učení je běžnou praxí stanovit základní referenční model (baseline), jehož validační metriky budou snahou překonat komplexnějšími modely. Zásadním krokem je volba vhodné architektury neuronové sítě odpovídající povaze problému. V oblasti predikce výkonu FVE se často využívají rekurentní neuronové sítě (RNN) a jejich varianta LSTM (Long Short-Term Memory), které umožňují efektivní modelování časových závislostí. Alternativně lze aplikovat konvoluční neuronové sítě (CNN), jež se uplatňují primárně v počítačovém vidění [21,22].

Důležitou součástí návrhu modelu je konfigurace hyperparametrů, jako jsou například: velikost dávky (batch size), rychlost učení (learning rate) a volba aktivačních funkcí. Tyto parametry zásadně ovlivňují rychlost konvergence i výslednou přesnost modelu. Optimalizace probíhá empiricky nebo pomocí metod automatického vyhledávání, například pomocí nástroje KerasTuner [21,22] .

Na rozdíl od tradičních metod strojového učení, které často vyžadují úpravu rysů (feature engineering), umožňuje hluboké učení automatickou extrakci relevantních rysů přímo z dat. Díky tomu se osvědčilo v oblastech, jako je rozpoznávání obrazu, zpracování přirozeného jazyka nebo predikce složitých časových řad jako je například predikce výkonu fotovoltaických elektráren [21].




Obr. 12. Princip hlubokého učení [21].

6.1 Perceptron

Perceptron (Obr. 13) představuje nejjednodušší architekturu neuronové sítě, která obsahuje jediný neuron. Přijímá vstupy $x_1, x_2, \dots, x_m$ z nichž každý má přiřazenou váhu $w_1, w_2, \dots, w_m$, určující jeho důležitost. Dále obsahuje tzv. práh (bias) w_0 , který ovlivňuje posun výsledné hodnoty[29][30].

Výpočet výstupní hodnoty perceptronu zobrazuje Rovnice 14. Probíhá tak, že jednotlivé vstupy x_i se vynásobí odpovídajícími váhami w_i , výsledné součiny se sečtou a přičte se k nim práh w_0 . Na tento součet se následně aplikuje aktivační funkce, obvykle nelineární, aby umožnila neuronové síti modelovat složitější vztahy [29,30].

Často se tato rovnice přepisuje do lineární algebry, kde $\mathbf{X}$ je vektor vstupů a $\mathbf{W}$ je vektor vah. Tento zápis vyjadřuje Rovnice 15 [30].



Obr. 13. Perceptron[30]

$$\hat{y} = g \left(w_0 + \sum_{i=1}^m x_i w_i \right)$$

Rovnice 14. Výpočet výstupní hodnoty perceptronu [30].

Kde:

- $\hat{y}$ – *výstupní hodnota* (predikovaná hodnota)
- g – aktivační funkce
- w_0 – práh (bias)
- x_i – i-tá vstupní hodnota
- w_i – odpovídající váha vstupu x_i


$$\hat{y} = g(w_0 + \mathbf{X}^T \mathbf{W})$$

Rovnice 15. Výpočet výstupní hodnoty perceptronu v lineární algebře [30].

Kde:

- $\hat{y}$ – *výstupní hodnota* (predikovaná hodnota)
- g – aktivační funkce
- w_0 – práh (bias)
- $\mathbf{X}$ – vektor vstupních hodnot
- $\mathbf{W}$ – vektor vah

Pro vytvoření více výstupů se do neuronové sítě přidávají další perceptrony. Takto vzniká plně propojená síť (dense layer - Obr. 14), kde každý neuron přijímá stejné vstupy, ale má přiřazené k těmto vstupům jiné váhy, a proto každý neuron bude mít i jiné výsledné hodnoty [30].




Obr. 14. Plně propojená síť [30].

6.2 Aktivační funkce

Aktivační funkce přidávají modelu nelinearitu, což mu umožňuje zachytit složitější vztahy v datech. Důležitými vlastnostmi aktivační funkce jsou diferencovatelnost, která je nezbytná pro výpočet gradientu, a v ideálním případě nelinearita, jež umožňuje modelu efektivně se učit komplexní vzory. Mezi běžně používané aktivační funkce v regresních úlohách se řadí hyperbolický tangens (tanh), ReLU (Rectified Linear Unit) a lineární funkce [31].

6.2.1 Lineární funkce

Lineární funkce (Graf 1) představuje nejjednodušší typ aktivační funkce, která je definována na celém číselném intervalu $(-\infty; +\infty)$. Tato funkce vrací stejnou hodnotu, jaká je zadána na vstupu (Rovnice 16). Lineární aktivační funkce se využívá především ve výstupní vrstvě neuronové sítě při řešení regresních úloh za účelem predikce číselných hodnot [31].



Graf 1. Lineární aktivační funkce [31].


$$F(x) = x$$

Rovnice 16. Lineární aktivační funkce [31].

6.2.2 Hyperbolický tangens

Hyperbolický tangens (Graf 2) je nelineární aktivační funkcí, který transformuje vstupní hodnoty do intervalu $(-1; 1)$. Je symetrický kolem 0, což umožňuje rychlejší konvergenci k optimálním vahám neuronové sítě. Nevýhodou této funkce však je náchylnost k problému mizejícího gradientu, kdy se během zpětného šíření chyby gradient

stává extrémně malým, což zpomaluje učení hlubokých neuronových sítí. Často se využívá ve skrytých vrstvách. Rovnice 17 zobrazuje jeho definici [31,32].




Graf 2. Hyperbolický tangens [31].

$$F(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Rovnice 17. Definice hyperbolického tangens [31].

6.2.3 RELU (Rectified Linear Unit)

ReLU (*Graf 3*) je nelineární aktivační funkcí, která pro záporné vstupní hodnoty vrací nulu a pro nezáporné hodnoty se chová jako lineární funkce. Její výhodou oproti hyperbolickému tangens je nižší výpočetní náročnost. *Rovnice 18* zobrazuje její definici [31].



Graf 3. RELU [31].

$$F(x) = \max(0, x)$$

Rovnice 18. Definice RELU [31].

6.3 Trénování neuronové sítě

Cílem trénování neuronové sítě na datové sadě je minimalizovat ztrátovou funkci vhodným nastavením vah (*Obr. 15*). K tomu se využívá metoda gradientního sestupu, která spočívá ve výpočtu parciálních derivací ztrátové funkce vzhledem k jednotlivým vahám. Metoda informuje, jak malá změna vah ovlivní velikost ztráty. Gradient ukazuje směr největšího růstu ztrátové funkce, a proto se váhy aktualizují v opačném směru, aby se ztráta snížila [21,33].

Tento proces probíhá iterativně tak, že se váhy upraví o malý krok, jehož velikost je určena rychlostí učení (learning rate). Nesprávné nastavení rychlosti učení může negativně ovlivnit výsledky modelu, kdy příliš nízká hodnota může způsobit pomalou konvergenci nebo uvíznutí v lokálním minimu, zatímco příliš vysoká může vést k nestabilnímu učení a přeskočení globálního minima [22].

Algoritmus gradientního sestupu lze shrnout následovně:

1. Inicializace: náhodně se nastaví váhy neuronové sítě
2. Iterace, dokud nedojde ke konvergenci:

- Vypočítá se gradient: $\frac{\partial J(W)}{\partial W}$
- Aktualizují se váhy: $W_{n+1} = W - \eta \frac{\partial J(W)}{\partial W}$


Kde:

W - vektor vah

η - rychlost učení

J - ztrátová funkce

3. Výstup: optimalizované váhy



Obr. 15. Gradientní sestup [22].

6.4 Hluboké učení pro časové řady

Časová řada (timeseries) je údaj získaný měřením v pravidelných intervalech jako je například denní cena akcie, produkovaný hodinový výkon fotovoltaické elektrárny. Práce s časovými řadami zahrnuje pochopení dynamiky systému – jeho periodických cyklů jenž jsou charakterizovány jako vzestupy a poklesy za nefixované období, nebo časové řady ovlivněné sezonními faktory, jako je roční období, jeho trendů v čase, kdy má časová řada dlouhodobý růst nebo pokles (nemusí být lineární), pravidelného režimu i náhlých výkyvů. Typickou úlohou v časových řadách je určit jaká bude následující hodnota. Jako je například predikce výroby elektřiny na několik hodin dopředu [21].

Jelikož při práci s časovými řadami dat se predikují budoucí hodnoty, tak je důležité používat validační a testovací data, která jsou novější než trénovací data [21].


Vstupní data do neuronové sítě pro časové řady jsou reprezentována třírozměrným tenzorem ve tvaru (počet vzorků, délka časového okna, počet rysů), viz Obr. 16. Tento tenzor obsahuje explicitní časovou osu, která je podle konvence vždy druhou osou [21].

Například v případě meteorologické stanice, která každou hodinu zaznamenává hodnoty slunečního záření, okolní teploty, teploty panelů a rychlosti větru, by data za jeden týden odpovídala tenzoru tvaru (7, 24, 4), kde:

- 7 představuje počet vzorků (každý den jeden vzorek)
- 24 odpovídá délce časového okna (24 hodin za den)


- 4 označuje počet rysů (sluneční záření, okolní teplota, teplota panelů a rychlost větru)

Každý vzorek tedy obsahuje data za jeden den [21].



Obr. 16. 3D tenzor časových dat [21].

Při predikci časových řad, jako je například výkon fotovoltaických elektráren, se pracuje s pojmy horizont a okno (Obr. 17), které slouží k transformaci časových řad na úlohu učení s učitelem. Horizont (angl. horizon) označuje počet časových kroků, které model předpovídá do budoucnosti, například predikce výkonu na následujících osm hodin. Okno (angl. window) představuje počet časových kroků z minulosti, které model využívá k této predikci (Obr. 17). Velikost okna určuje, jak velkou část historických dat model zohledňuje, což může mít zásadní vliv na přesnost predikce, zejména při sezónních nebo periodických jevech. Jedná se o hyperparametry, jejichž volba má zásadní vliv na efektivní učení modelu a dosažení co nejpřesnějších predikcí [21].



Obr. 17. Příklad oken a horizontů pro bitcoinová data [34].

6.4.1 Křížová validace časových řad


Při predikci časových řad je důležité zachovat jejich kontinuitu, a proto nelze vzorky pro trénovací, validační a testovací sady vybírat náhodně. V takovém případě by se model učil z budoucích dat, což by vedlo k optimistickému zkreslení odhadu přesnosti modelu. Proto se pro validaci modelů na časových řadách využívá speciální metoda křížové validace časových řad, která zajišťuje, že testovací sady vždy následují po

tréninkových sadách v čase. Nejčastěji se používá jedna z následujících tří technik: jednoduché časové rozdělení (Simple Time-Split Validation), křížová validace klouzavého okna (Rolling Window Cross-Validation) a křížová validace rozšiřujícího se okna (Expanding Window Cross-Validation) [35].

6.4.1.1 Jednoduché časové rozdělení (Simple Time Split Validation)

Jednoduché časové rozdělení (Obr. 18) spočívá v jednorázovém rozdělení dat na trénovací a validační sadu v určitém časovém bodě. Jedná se o nejjednodušší techniku validace časových řad, protože nevyžaduje iterativní trénování modelu na více podmnožinách dat [35].

Jednoduché časové rozdělení
(Simple Time Split Validation)




Obr. 18. Jednoduché časové rozdělení [35].

6.4.1.2 Křížová validace klouzavého okna (Rolling Window Cross-Validation)

Křížová validace klouzavého okna (Obr. 19) spočívá v postupném posouvání okna o pevně dané délce přes časovou řadu. Model se vždy trénuje na aktuálním okně dat a následně se testuje na nejbližším následujícím okně. Tento proces se opakuje, takže model se postupně učí na různých úsecích časové řady [35,36].

Tato metoda zachycuje nejnovější vzory v datech, protože validace probíhá vždy na nejaktuálnějších hodnotách. Nevýhodou však je, že model postupně ztrácí přístup ke starším datům, což může vést k horší schopnosti rozpoznávat dlouhodobé vzory, například sezónní změny ve výrobě elektrické energie z fotovoltaických elektráren [37].


Křížová validace klouzavého okna (Rolling Window Cross-Validation)



Obr. 19. Křížová validace klouzavého okna [35].

6.4.1.3 Křížová validace rozšiřujícího se okna (Expanding Window Cross-Validation)

Křížová validace rozšiřujícího se okna (Obr. 20) začíná s menším množstvím trénovacích dat, která se s každým dalším validačním krokem postupně rozšiřují o novější záznamy, až pokryjí celou časovou historii. Tato metoda umožňuje modelu učit se z většího množství dat, což může zlepšit jeho schopnost rozpoznávat dlouhodobé vzory. Na druhou stranu může zahrnutí příliš starých dat vést ke snížení relevance modelu, pokud se podmínky v čase výrazně změnily [35–37].




Obr. 20. Křížová validace rozšiřujícího se okna [35].

6.4.2 Rekurentní neuronové sítě (RNN)

Rekurentní neuronová síť (recurrent neural network – RNN) je navržena pro práci se sekvenčními daty tím, že je schopna se naučit časové závislosti a vzory v datech a na jejich základě predikovat budoucí hodnoty. Její princip spočívá ve zpětné vazbě, kde se v každém časovém kroku t přenáší informace, jako je skrytý stav sítě nebo v některých případech i výstup, do následujícího časového kroku $t + 1$. [22].

Obr. 21 na levé části ukazuje rekurentní neuron sítě, který přijímá vstup, vytváří výstup a posílá tento výstup přes zpětnou vazbu zpátky k sobě. V každém časovém kroku t tento rekurentní neuron přijímá vstupy $x(t)$ a také svůj vlastní výstup z předchozího časového kroku $y(t-1)$. Protože v prvním časovém kroku neexistuje žádný předchozí výstup, je obecně nastaven na nulu. Tato síť může být znázorněna na časové ose (jedná se o stejný neuron rozložený do časových kroků t), jak je znázorněno na pravé části Obr. 21. Čili výstup neuronu je dán nejen vstupem, ale je ovlivněn i předchozí výstupní hodnotou [22].




Obr. 21. Rekurentní neuron a rozvinutí sítě v čase [22].

Přestože jsou RNN schopné modelovat sekvenční závislosti, potýkají se s jedním zásadním problémem, známým jako problém mizení gradientu (*vanishing gradient problem*). Kvůli tomu jsou schopné se z dat naučit pouze krátkodobé vzory, běžně pouze tak 10 kroků zpátky (záleží na řešené úloze), po chvíli tak dojde k zapomnění již prvních vstupů. Tento problém vzniká během procesu učení při zpětném šíření chyby skrze čas (backpropagation through time, BPTT). V důsledku opakovaného násobení gradientů v mnoha časových krocích může docházet k exponenciálnímu útlumu hodnot gradientů. To má za následek, že síť nedokáže efektivně aktualizovat váhy neuronů v dřívějších vrstvách, čímž ztrácí schopnost uchovávat a využívat informace o dlouhodobých závislostech v datech [21,34].

V praxi se využívají pokročilejší architektury, které byly navrženy tak, aby tento problém řešily, jako jsou dlouhé krátkodobé paměti LSTM (Long Short-Term Memory) [21].

6.4.3 Algoritmus dlouhé krátkodobé paměti

Algoritmus dlouhé krátkodobé paměti (Long Short-Term Memory, LSTM) je specializovaná architektura rekurentní neuronové sítě (RNN), navržená pro efektivní zpracování a uchovávání dlouhodobých závislostí v sekvenčních datech. Hlavní myšlenkou LSTM je schopnost selektivně určovat, které informace si síť uchová v paměti, které zapomene a které využije pro aktuální predikce [21,22].



Obr. 22. LSTM buňka [22].

Obr. 22 ukazuje architekturu LSTM buňky. Dlouhodobý stav $c_{(t-1)}$ prochází sítí zleva doprava. Nejprve vstupuje do zapomínací brány (forget gate), která rozhoduje, které informace z minulosti budou zapomenuty. Následně se k upravenému dlouhodobému stavu přidávají nové informace pomocí sčítací operace. Tyto nové informace jsou vybrány vstupní bránou (input gate). Výsledný stav $c_{(t)}$ je pak bez další transformace uchován jako nový dlouhodobý stav [22].

V každém časovém kroku jsou tedy některé informace odebrány a jiné jsou přidány. Po této sčítací operaci je dlouhodobý stav $c_{(t)}$ dále zpracován pomocí aktivační funkce tanh, která normalizuje hodnoty do rozsahu $(-1; 1)$. Výsledek této transformace je poté filtrovaný výstupní bránou (output gate), která určuje, které informace se dostanou do krátkodobého stavu $h_{(t)}$, jenž slouží i jako výstup buňky $y_{(t)}$ pro daný časový krok [22].

Pro aktualizaci paměti se nejprve aktuální vstupní vektor $x_{(t)}$ a předchozí krátkodobý stav $h_{(t-1)}$ přivedou do čtyř plně propojených vrstev, z nichž každá plní specifickou funkci:

4. **Vrstva generující kandidátní hodnoty $g_{(t)}$** analyzuje aktuální vstup $x_{(t)}$ a předchozí krátkodobý stav $h_{(t-1)}$. V jednoduché RNN je tento výstup přímo předán jako výsledek. V LSTM je však pouze nejdůležitější část těchto informací přidána do dlouhodobé paměti, zbytek je zahozen [22].

5. **Zapomínací brána (forget gate):** Určuje, které informace z paměťového stavu $c_{(t-1)}$ budou zapomenuty. Je řízena aktivační funkcí $f_{(t)}$, která využívá sigmoidální funkci s výstupem v rozsahu (0; 1). Výsledek této funkce slouží jako filtr: hodnoty blízké 0 způsobují potlačení příslušných informací, zatímco hodnoty blízké 1 umožňují jejich zachování v paměťovém stavu [22].
6. **Vstupní brána (input gate):** Rozhoduje o tom, které nové informace ze vstupního vektoru $x_{(t)}$ a předchozího skrytého stavu $h_{(t-1)}$ budou přidány do paměťového stavu. Je řízena aktivační funkcí $i_{(t)}$, která stejně jako zapomínací brána využívá sigmoidální funkci k určení, které informace budou přeneseny dál [22].
7. **Výstupní brána (output gate):** Řídí, které informace z paměťového stavu mají být na výstupu sítě $h_{(t)}$. Je řízena funkcí $o_{(t)}$, která opět využívá sigmoidální aktivační funkci. Výsledek této funkce určuje, které části zpracovaných dat budou aktivovány a předány do výstupní vrstvy [22].

Buňka LSTM se učí rozpoznávat důležité informace (úkol vstupní brány), ukládat je do paměti na libovolně dlouhou dobu (úkol zapomínací brány) a v pravý okamžik je z paměti vyvolat (úkol výstupní brány). Díky této struktuře jsou LSTM sítě úspěšné při zpracování sekvenčních dat, jako jsou časové řady, texty, zvukové záznamy a další [22].

6.4.3.1 Výpočty v LSTM buňce

Matematické rovnice, které popisují výpočty dlouhodobého stavu buňky, krátkodobého stavu a výstupu v každém časovém kroku t , jsou následující:

1. **Zapomínací brána (forget gate):**

$$f_{(t)} = \sigma(W_{xf} \cdot x_{(t)} + W_{hf} \cdot h_{(t-1)} + b_f)$$

2. **Vstupní brána (input gate) a kandidátní hodnoty:**

$$i_{(t)} = \sigma(W_{xt} \cdot x_{(t)} + W_{ht} \cdot h_{(t-1)} + b_i)$$

$$g_{(t)} = \tanh(W_{xg} \cdot x_{(t)} + W_{hg} \cdot h_{(t-1)} + b_g)$$

3. **Aktualizace paměťového stavu:**

$$c_{(t)} = f_{(t)} \odot c_{(t-1)} + i_{(t)} \odot g_{(t)}$$

4. **Výstupní brána (output gate) a výstup buňky:**

$$o_{(t)} = \sigma(W_{xo} \cdot x_{(t)} + W_{ho} \cdot h_{(t-1)} + b_o)$$

$$y_{(t)} = h_{(t)} = o_{(t)} \odot \tanh c_{(t)}$$

Kde:

- σ - sigmoidová aktivační funkce, vracející hodnoty v rozsahu (0, 1),
- $\tanh$ - hyperbolická tangens, normalizující hodnoty mezi (-1, 1),
- W a b - váhové matice a biasy jednotlivých bran,
- $x_{(t)}$ - vstupní vektor v čase t ,
- $h_{(t-1)}$ - krátkodobý (skrytý) stav z předchozího časového kroku,
- $c_{(t)}$ - paměťový (dlouhodobý) stav buňky v čase t ,
- $\odot$ - Hadamardův součin.


6.4.4 Konvoluční neuronové sítě (CNN)

Konvoluční neuronové sítě (CNN) se učí lokální vzory, které následně dokážou rozpoznat kdekoliv ve vstupních datech – na rozdíl od plně propojených sítí, které pracují s globálními vztahy mezi vstupy. Jsou primárně navrženy pro analýzu strukturovaných dat, zejména obrazů [21].

Využívají se převážně pro zpracování obrazových dat, avšak CNN také jsou výkonné i pro analýzu časových řad. Namísto analýzy prostorových vzorů v obrázcích mohou být využity k detekci vzorců v sekvenčních datech. V těchto případech CNN nejen slouží jako alternativa k tradičním rekurentním neuronovým sítím (RNN, LSTM), ale také s nimi efektivně spolupracují. CNN je schopna extrahovat významné vzory z časových řad, které pak LSTM vrstvy mohou lépe zpracovat a využít pro predikci dlouhodobých závislostí. Příkladem může být predikce počasí, kde CNN detekuje vzory v meteorologických datech a LSTM modeluje jejich časový vývoj [21,22].

Konvoluční vrstva je tvořena mnoha filtry, které postupně procházejí vstupními daty (nejčastěji obrázky) a učí se v nich detekovat lokální vzory odpovídající jejich velikosti. Filtry jsou v podstatě malé matice čísel, které se posouvají vždy o konkrétní počet kroků (stride) po obrázku. Na každou překrytou oblast vstupního obrazu se aplikuje Hadamardův součin (prvkový součin mezi filtrem a odpovídající částí vstupní matice, následovaný sumací), čímž vznikají matice příznaků (feature maps). Tyto matice určují, kde se v původním obrazu vyskytují dominantní části detekovaných vzorů, jako jsou hrany, textury či tvary [21,22].

Konvoluční vrstva se automaticky během trénování naučí nejužitečnější filtry pro daný úkol a vrstvy výše se naučí kombinovat tyto extrahované rysy do složitějších vzorů podobně jako je znázorněno na Obr. 23 [21].



Obr. 23. Extrakce hierarchického učení rysů [21].

7 Příprava a analýza dat

7.1 Fotovoltaická elektrárna ABA

Predikční model je tvořen pro fotovoltaickou elektrárnu ABA, jenž se nachází v obci Kunžak. Disponuje výkonem 1 293 kWp. Je složena z 5 625 fotovoltaických panelů, konkrétně se jedná o typy:

- TW230Wp – 1148 ks
- TW235Wp – 1008 ks
- YLG230Wp – 3231 ks
- YLG235Wp – 238 ks

Každý tento typ panelu má nominální výkon 230 Wp s přípustnou tolerancí ± 5 %. Panely v době porřízení měly účinnost 14,1 %. Každý panel je tvořen ze 60 fotovoltaických článků, jenž každý disponuje rozměry 156 x 156 mm. Celková velikost

plochy jednoho panelu odpovídá 1, 460 m². Celková aktivní plocha osvitu elektrárny činí 8 213,4 m². Panely jsou orientovány na jih, tedy azimut je 180° se sklonem 35° pro dosažení optimálního zisku slunečního záření.

Pro přeměnu generovaného stejnosměrného proudu na střídavý jsou použity měniče SMC 10000RP, které původně měly účinnost 98 %. Aktuálně se jejich účinnost pohybuje v rozmezí 96–98 %, což je důsledkem vysychání elektrolytu v kondenzátorech.

7.2 Analýza dat

Pro trénink modelu byly použity následující datasety z různých zdrojů:

7.2.1 Data od společnosti Solarmon

Společnost Solarmon poskytla dva soubory historických dat ve formátu .csv, konkrétně:

- mon_sensor_box_hour.csv
- mon_substation_items_hour.csv

Soubor mon_sensor_box_hour.csv obsahuje zprůměrovaná meteorologická data z blízké meteostanice, zaznamenaná v hodinových intervalech od 13. prosince 2010 do 5. října 2024. Tento dataset zahrnuje následující proměnné:

- Me – sluneční záření [W/m²]
- to – okolní teplota [°C]
- tp – teplota panelu [°C]
- w – rychlost větru [m/s]
- timestamp – časový údaj ve formátu MM/DD/YYYY hh:mm:ss AM/PM (např. 05/19/2011 03:59:58 PM)

Soubor mon_substation_items_hour.csv obsahuje zprůměrovaná data z elektroměru o vyrobené energii, zaznamenaná v hodinových intervalech od připojení elektrárny (19. května 2011) do 5. října 2024. Tento dataset zahrnuje sloupce:

- impuls – počet impulsů, kde 1 impuls po období 28.8.2019 odpovídá 500 Wh vyrobené energie.
- timestamp – časový údaj ve formátu MM/DD/YYYY hh:mm:ss AM/PM (např. 05/19/2011 03:59:58 PM)

7.2.2 Data od společnosti Amper Meteo

Společnost Amper Meteo poskytla dva datasety s historickými meteorologickými daty:

- data_meteo.csv
- data_pvlib.csv

Dále byly poskytnuty satelitní snímky.

Soubor data_meteo.csv obsahuje zprůměrovaná meteorologická data za hodinový interval (např. hodnota v 10:00 UTC odpovídá průměru od 10:00 do 11:00 UTC), pokrývající období 2020 až 2023. Data slunečního záření byla získána váženým průměrem, kdy váha postupně klesá směrem od středu kruhové oblasti se středem v místě FVE a poloměrem 15 km. Ostatní meteorologické parametry byly určeny z nejbližšího gridového bodu numerických meteorologických modelů k místu FVE. Dataset zahrnuje tyto meteorologické parametry:

- DT - časový údaj ve formátu YYYY-MM-DD HH:MM:SS±HH:MM (např. 2020-01-01 00:00:00+00:00)
 - Datum ve formátu YYYY-MM-DD
 - Čas ve formátu HH:MM:SS
 - Časové pásmo vyjádřené jako ±HH:MM
- RAD – Globální sluneční záření (RAD) [W/m^2]
- T2M – Teplotu ve výšce 2 metrů (T2M) [$^{\circ}\text{C}$]
- WS10M – Rychlost větru ve výšce 10 metrů (WS10M) [m/s]

Soubor data_pvlib.csv obsahuje meteorologická data v 15minutových intervalech za stejné období (2020–2023). Časové řady představují průměrné hodnoty za interval (např. hodnota v 10:00 UTC odpovídá průměru od 10:00 do 10:15 UTC). Dataset zahrnuje následující proměnné:

- DT - časový údaj ve formátu YYYY-MM-DD HH:MM:SS±HH:MM (např. 2020-01-01 00:00:00+00:00)
 - Datum ve formátu YYYY-MM-DD
 - Čas ve formátu HH:MM:SS
 - Časové pásmo vyjádřené jako ±HH:MM
- ZENITH – Výšku slunce nad obzorem (ZENITH) [$^{\circ}$]
- AZIMUTH – Azimut slunce (AZIMUTH) [$^{\circ}$]

- RAD_MAX – Maximální množství globálního slunečního záření [W/m^2] pro daný čas

7.2.3 Data z OpenMeteo

OpenMeteo poskytuje API umožňující přístup k rozsáhlým historickým meteorologickým údajům, přičemž data jsou dostupná v hodinovém časovém rozlišení pro libovolné souřadnice na zemské kouli. Pro zvýšení přesnosti modelu bylo experimentováno s rozšířením stávajících datových sad pro danou oblast o:

- Surface_pressure – Atmosférický tlak [hPa]
- Humidity – Vlhkost vzduchu [%]
- Wind_direction_10m – Směr větru [$^\circ$]
- Cloud_Cover – Oblačnost [%]
- Precipitation – Srážky [mm/h]
- DHI – Difuzní záření [W/m^2]
- DNI – Přímé sluneční záření [W/m^2]
- Shortwave_radiation – Krátkovlnné záření [W/m^2]
- Dew_point – Teplotu rosného bodu [$^\circ\text{C}$]
- Ozone – koncentrace ozónu ve výšce 10 m [$\mu\text{g/m}^3$]
- PM10 – koncentrace prachových částic s průměrem menším než 10 μm [$\mu\text{g/m}^3$]

7.2.4 Transformace dat pro model

Za využití knihovny PVLIB byly do datové sady přidány nové proměnné AOI a následně IAM. AOI (Angle of Incidence) udává úhel mezi normálou panelu a dopadu slunečních paprsků na fotovoltaický panel čili pro $\text{AOI} = 0^\circ$ odpovídá situaci, kdy sluneční paprsky dopadají kolmo na panel. Pro jeho výpočet je potřeba znát zenit a azimut panelů, stejně jako zenit a azimut slunce. Proměnná IAM (Incidence Angle Modifier) udává koeficient v rozsahu 0 až 1, který určuje, jak efektivně panel absorbuje sluneční záření při daném úhlu dopadu slunečních paprsků AOI. Pro tento výpočet je využit fyzikální model ASHRAE (American Society of Heating, Refrigerating and Air-Conditioning Engineers), který popisuje vliv úhlu dopadu na účinnost absorpce [38].

Dále byly z časových údajů (datetime) vytvořeny nové cyklické proměnné sin_hour, cos_hour podle Rovnice 19 a Rovnice 20, které popisují denní cyklus. Následně byly na základě Rovnice 21 a Rovnice 22 vytvořeny cyklické proměnné sin_day_of_year a cos_day_of_year, které zachycují sezónní periodicitu. Tyto proměnné umožňují modelu lépe zachytit vliv časových změn na výkon fotovoltaické elektrárny, čímž zvyšují přesnost predikcí modelu.

$$\sin_{hour} = \sin\left(\frac{2\pi \cdot hodina}{24}\right)$$

Rovnice 19. Výpočet proměnné $\sin_{hour}$.

$$\cos_{hour} = \cos\left(\frac{2\pi \cdot hodina}{24}\right)$$

Rovnice 20. Výpočet proměnné $\cos_{hour}$.

$$\sin_{day_of_year} = \sin\left(\frac{2\pi \cdot den_v_roce}{365}\right)$$

Rovnice 21. Výpočet proměnné $\sin_{day_of_year}$.

$$\cos_{day_of_year} = \cos\left(\frac{2\pi \cdot den_v_roce}{365}\right)$$

Rovnice 22. Výpočet proměnné $\cos_{day_of_year}$.

Později byly do datové sady přidány další dvě proměnné $wind_u$ a $wind_v$, které byly vypočítány z proměnných rychlost větru ve výšce 10 m (WS10M) a směr větru ve výšce 10 m ($wind_direction_10m$) podle Rovnice 23 a Rovnice 24. Proměnná $wind_u$ reprezentuje složku větru ve směru východ-západ, kde pozitivní hodnoty označují vítr vanoucí směrem k východu a negativní hodnoty znamenají vítr vanoucí směrem k západu. Podobně proměnná $wind_v$ reprezentuje složku větru ve směru sever-jih, kde pozitivní hodnoty indikují vítr směřující na jih a negativní hodnoty vítr směřující na sever. Experimenty ukázaly, že tato kombinace proměnných nejvíce přispívá k vyšší přesnosti modelu.

$$wind_u = WS10M \cdot \cos(wind_direction_10m)$$


Rovnice 23. Výpočet síly větru ve směru východ-západ.

$$wind_v = WS10M \cdot \sin(wind_direction_10m)$$


Rovnice 24. Výpočet síly větru ve směru sever-jih.

7.3 Analyzovaná data


V následujících grafech jsou zobrazena data od 28. 8. 2019, kdy došlo k výměně elektroměru. Graf 4 zobrazuje průměrný výkon v kW zaznamenaný po hodinách za období od 28. 8. 2019 do 4. 10. 2024. Na grafu je zřetelně vidět roční periodicitu. Graf 5 vyobrazuje denní periodicitu výkonu. Graf 6 zobrazuje průměrný měsíční výkon FVE.



Graf 4. Vynesený výkon za období 28.8.2019 až 4.10.2024 měření.




Graf 5. Výkon FVE v prvních deseti dnech.



Graf 6. Průměrný výkon v měsících.


7.4 Sezonní analýza:

Graf 7 znázorňuje průměrný výkon fotovoltaické elektrárny během roku v jednotlivých měsících. Z něj vyplývá, že nejvyšší produkce výkonu nastává v letních měsících, konkrétně v červnu a červenci, kdy je sluneční záření nejintenzivnější. Naopak nejnižší výkon je zaznamenán v zimních měsících, zejména v prosinci a lednu, což lze přičíst, nižším úhlům slunečního záření a častější oblačnosti.




Graf 7. Průměrný výkon FVE v jednotlivých měsících.

Graf 8 znázorňuje průměrné hodnoty výkonu fotovoltaické elektrárny rozdělené podle ročních období. Nejvyšší produkce energie je zaznamenána v letním období, což souvisí s vyšší intenzitou slunečního záření. Následuje jaro, kdy se zvyšuje množství dopadajícího slunečního záření. Podzimní měsíce vykazují nižší výkon než jarní, což je způsobeno vyšší oblačností. Nejnižší výkon je v zimním období, kdy je slunečního záření nejméně a úhel dopadu slunečních paprsků je nejmenší.




Graf 8. Průměrný výkon v ročních obdobích

Graf 9 znázorňuje průměrný průběh slunečního záření a výkonu fotovoltaické elektrárny během dne, vypočtený jako průměrná hodnota výkonu pro jednotlivé hodinové úseky za celé sledované období. Z grafu je patrné, že výkon začíná narůstat po východu slunce, dosahuje maxima v poledních hodinách, kdy je sluneční záření nejintenzivnější, a následně klesá až na nulovou hodnotu po západu slunce. Průběh odpovídá dennímu cyklu slunečního záření a je ovlivněn faktory, jako jsou roční období, oblačnost a úhel dopadu slunečních paprsků. Pro lepší srovnání je dále uveden Graf 10 s průběhy průměrného denního výkonu v červnu, kdy je výkon nejvyšší a v lednu, kdy je naopak nejnižší s odpovídajícím slunečním zářením.




Graf 9. Průměrný denní průběh výkonu.




Graf 10. Průměrný výkon za měsíc červen a leden s odpovídajícím slunečním zářením.

Graf 11 znázorňuje součet vyprodukované elektrické energie v kWh za jednotlivé měsíce v roce. Nejnižší produkce je v zimních měsících (prosinec, leden), od jara výroba začíná růst a nejvyšší produkce se dosahuje v červenci. Na podzim opět dochází k poklesu


výroby. Graf 12 zobrazuje součet vyprodukované energie v měsících rozložených za všechny roky. Graf 13 poté zobrazuje průměrný výkon za jednotlivé měsíce během let 2019 až 2024.



Graf 11. Součet vyprodukované energie za jednotlivé měsíce.




Graf 12. Součet vyprodukované energie za jednotlivé měsíce.



Graf 13. Průměrný výkon FVE ABA podle měsíců za jednotlivé roky.

Graf 14 zobrazuje průměrné měsíční hodnoty okolní teploty (to) a teploty fotovoltaických panelů (tp) během celého roku. Z grafu je patrné, že teplota panelů je ve všech měsících vyšší než okolní teplota, přičemž rozdíl mezi těmito hodnotami se zvyšuje v letních měsících.


Největší rozdíl je patrný v červnu, červenci a srpnu, kdy teplota panelů dosahuje v průměru o 4–6 °C vyšších hodnot než okolní teplota. Tento jev je způsoben absorpcí slunečního záření, které zahřívá panely nad úroveň okolní teploty. Naopak v zimních měsících (prosinec, leden, únor) je rozdíl mezi teplotou panelů a okolní teplotou minimální, což odpovídá nižší intenzitě slunečního záření.



Graf 14. Měsíční průměrné teploty panelů (tp) a okolní (to).

Graf 15 znázorňuje průměrné měsíční hodnoty slunečního záření (Me) v jednotkách W/m^2 . Z grafu je patrný výrazný sezónní trend, kdy nejvyšší hodnoty slunečního záření dosahují v letních měsících (červen, červenec) průměrné hodnoty přesahující 225 W/m^2 . Naopak nejnižší hodnoty jsou v zimních měsících (prosinec, leden), kdy průměrná hodnota klesá pod 50 W/m^2 .


Pro fotovoltaické elektrárny je sluneční záření samozřejmě klíčovým faktorem ovlivňujícím výrobu elektrické energie. Vysoké hodnoty slunečního záření v letních měsících zvyšují potenciál výroby, zatímco v zimních měsících je produkce přirozeně nižší.



Graf 15. Průměrné měsíční hodnoty slunečního záření.

Graf 16 znázorňuje průměrné měsíční hodnoty rychlosti větru (w) v průběhu roku. Z grafu je patrné, že rychlost větru vykazuje sezónní variabilitu, přičemž nejvyšších hodnot dosahuje v zimních měsících (leden, únor, listopad, prosinec), kdy průměrná rychlost větru přesahuje 1,4 m/s. Naopak nejnižší průměrné rychlosti větru se vyskytují v letních měsících (červen, červenec, srpen), kdy klesají pod 0,8 m/s.

Rychlost větru je důležitým faktorem při hodnocení výkonu fotovoltaických panelů, protože ovlivňuje jejich chlazení. Vyšší rychlost větru podporuje odvod tepla z povrchu panelů, což přispívá ke snížení jejich provozní teploty a tím i ke zvýšení jejich účinnosti.



Graf 16. Průměrná měsíční rychlost větru.

7.5 Korelační analýza

Korelační matice slouží k identifikaci lineárních závislostí mezi jednotlivými rysy (features) v datech. Pomáhá vybrat relevantní rysy pro predikci výkonu. Matice je vypočítána pomocí Pearsonova korelačního koeficientu, který měří sílu a směr lineárního vztahu mezi dvěma proměnnými. Hodnoty koeficientu se pohybují v intervalu od -1 do 1, kde:

- 1 znamená dokonalou pozitivní korelaci
- 0 značí absenci lineární závislosti
- -1 znamená dokonalou negativní korelaci

První korelační matice na Obr. 24 zobrazuje závislost vybraných proměnných, které se experimentálně ukázaly jako optimální vstupy pro model. Tyto proměnné se nejvíce podílejí na predikci výkonu FVE. Obr. 25 zobrazuje lineární závislosti ostatních proměnných v datové sadě. Dále jsou popsány jednotlivé proměnné vzhledem k výkonu proměnné output.

7.5.1 Globální sluneční záření (RAD)

Globální sluneční záření (RAD) vykazuje nejvyšší pozitivní korelaci s výkonem 0,9, což potvrzuje očekávaný vliv intenzity slunečního záření na výrobu elektřiny. Vyšší intenzita záření přímo zvyšuje výkon fotovoltaických panelů.

7.5.2 Teplota panelů (tp)

Teplota panelů (tp) dosahuje vysoké korelace 0,79. Vyšší teplota panelů obvykle znamená vyšší výkon, protože je spojena s intenzivním slunečním zářením. Nicméně nad určitou hranicí může vysoká teplota snižovat účinnost panelů, což se zde částečně odráží v nižší korelaci oproti samotnému slunečnímu záření.

7.5.3 Ozon (Ozone)

Ozon má s výkonem FVE středně silnou negativní korelaci s hodnotou -0,47. Vyšší koncentrace ozonu bývá spojena se znečištěním ovzduší, které zvyšuje absorpci a rozptyl slunečního záření, a tím snižuje množství přímého záření dopadajícího na panely.

7.5.4 Vlhkost vzduchu (humidity)

Vlhkost vzduchu vykazuje s výkonem vysokou zápornou korelaci -0,68. Vyšší vlhkost vzduchu může signalizovat zvýšenou oblačnost a zvýšená koncentrace vodní páry ve vzduchu může také rozptylovat a absorbovat sluneční záření. Tyto jevy vedou ke snížení množství dopadajícího slunečního záření na fotovoltaické panely, což následně snižuje jejich výkon.

7.5.5 Oblačnost (cloud_cover)

Oblačnost má mírně negativní korelaci -0,18. Zvyšující se oblačnost obvykle snižuje intenzitu dopadajícího slunečního záření na fotovoltaické panely, což vede k poklesu výkonu. Negativní korelace je proto očekávaná.

7.5.6 Povrchový atmosférický tlak (surface_pressure)

Navzdory tomu, že lineární korelace mezi povrchovým atmosférickým tlakem a výkonem FVE dosáhla hodnoty pouze 0,15, což naznačuje velmi slabý vztah, nelze tento faktor zcela opomenout. Studie ukázaly, že vyšší atmosférický tlak vede k mírnému růstu výkonu; ačkoli je přímý vliv tohoto faktoru minimální, jeho zařazení do predikčních

modelů umožňuje zachytit jemnější atmosférické vzorce a mírně zlepšit přesnost predikcí [39].

7.5.7 Prachové částice (PM10)

Prachové částice (průměrem menším než 10 μm) vykazují téměř nulovou korelaci s výkonem FVE -0,011. Vysoké koncentrace PM10 však mohou nepřímo snižovat výkon rozptylem slunečního záření a dlouhodobým znečištěním povrchu panelů.

7.5.8 Složky větru ve směru východ-západ a sever-jih (wind_u, wind_v)

Složka větru wind_u vykazuje mírně nižší korelační koeficient 0,0093 s výkonem FVE oproti složce wind_v, která vykazuje korelační koeficient 0,032. Ačkoli tyto hodnoty naznačují jen velmi slabou souvislost, vítr může nepřímo pozitivně ovlivňovat výkon FVE ochlazením panelů a odstraňováním nečistot z jejich povrchu.

7.5.9 Časové proměnné (sin_hour, cos_hour, sin_day_of_year, cos_day_of_year)

Časové proměnné sin_hour a cos_hour vykazují korelační koeficienty s výkonem 0,11 resp. -0,65, což odráží denní cyklus – v noci je výkon nulový, zatímco během dne dosahuje maxima. Kombinace těchto proměnných umožňuje modelu lépe zachytit průběh výkonu během dne.

Časová proměnná sin_day_of_year vykazuje korelaci s výkonem 0,05 a cos_day_of_year vykazuje korelaci s výkonem -0,28. Tyto proměnné umožňují modelu efektivněji zachytit sezónní variace v intenzitě slunečního záření.

7.5.10 Maximální hodnota globálního slunečního záření (RAD_MAX)

Maximální sluneční záření za hodinu (RAD_MAX) má silnou korelaci s výkonem 0,82. Tento vztah je logický, protože intenzivní krátkodobé špičky záření mohou výrazně ovlivnit okamžitý výkon.

7.5.11 Přímé sluneční záření (DNI)

Přímé sluneční záření vykazuje silnou korelaci 0,79 s výkonem FVE. Tato složka již je zahrnuta v proměnné RAD.

7.5.12 Difuzní sluneční záření (DHI)

Difuzní sluneční záření představuje rozptýlené sluneční záření, které dopadá na panely. Vykazuje silnou lineární korelaci 0,71 s výkonem, avšak již je zahrnuté v globálním slunečním záření RAD.

7.5.13 Krátkovlnné sluneční záření (shortwave_radiation)

Krátkovlnné sluneční záření má jednu z nejsilnějších korelací s výkonem 0,89. Jedná se o elektromagnetické vlny s vlnovou délkou přibližně 0,2 až 4 μm , je již zahrnuto v globálním slunečním záření (RAD).

7.5.14 Úhel dopadu slunečních paprsků na panel (AOI)

Úhel dopadu slunečních paprsků na panel (AOI) vykazuje silně negativní korelaci s výkonem -0,69. Čím menší je tento úhel, tím kolměji dopadají sluneční paprsky na povrch panelu, což vede k efektivnější přeměně slunečního záření na elektrickou energii.

Překvapivě však model pro neuronové sítě s tímto parametrem vykazoval horší predikce.

7.5.15 Koeficient úhlu dopadu záření (IAM)

Koeficient úhlu dopadu záření (IAM) vykazuje silně pozitivní Pearsonův korelační koeficient 0,65 s výkonem FVE, což naznačuje, že optimální úhel dopadu slunečních paprsků významně zvyšuje výkon. Model založený na neuronových sítích s tímto parametrem však vykazoval horší predikční schopnost.

7.5.16 Okolní teplota (T2M)

Okolní teplota (T2M) vykazuje středně silnou korelaci s výkonem 0,46. Okolní teplota ovlivňuje výkon spíše nepřímo – teplejší dny jsou často spojeny s vyšší sluneční aktivitou, což zvyšuje množství dopadajícího slunečního záření, které zvyšuje výkon FVE.

Experimenty se ukázalo, že více vypovídající je pro model teplota panelů (tp), která přímo ovlivňuje účinnost fotovoltaických panelů.

7.5.17 Rychlost větru (WS10) a směr větru (wind_direction_10m)

Samotná rychlost větru a samotný směr větru má jen slabý vliv na výkon, korelace 0,033 resp. -0,065. Vítr primárně nemá přímý dopad na generování energie, ale může

pomoci nepřímou. Silnější vítr zlepšuje chlazení panelů, což v teplém počasí snižuje jejich teplotu a tím udržuje vyšší účinnost. Naopak, příliš silný vítr může zvyšovat riziko mechanického poškození, což negativně ovlivňuje výkon.

Pro model byla použita kombinace těchto proměnných ve formě `wind_u` a `wind_v`.

7.5.18 Zenit slunce (ZENITH)

Zenit slunce má výraznou negativní korelaci s výkonem -0,72. Vyšší zenit znamená, že slunce je níže na obloze, což snižuje intenzitu dopadajícího záření na panely a tím i výkon.

Samotný zenit predikce modelu nezlepšoval, to je dáno nejspíše tím, že jeho vliv je již zahrnut v globálním slunečním záření (RAD).

7.5.19 Azimut slunce (AZIMUTH)

Azimut slunce vykazuje téměř nulovou korelaci s výkonem 0,059, což naznačuje, že samotný azimut slunce nemá přímý vliv na výkon v rámci této datové sady. Tento závěr byl potvrzen i testováním, kdy azimut neměl téměř žádný vliv na predikce modelu.


7.5.20 Srážky (precipitation)

Srážky vykazují velmi slabou negativní korelaci s výkonem -0,042. Déšť sice snižuje přímé sluneční záření, ale tato informace může být již částečně zahrnuta v oblačnosti (`cloud_cover`). Srážky také mohou pomoci odstranit nečistoty z panelů, což má pozitivní účinek na výkon. Při experimentování, po zahrnutí srážek v kombinaci s proměnnou `clouds_cover`, již nedocházelo k výraznému zlepšení predikcí modelu.


7.5.21 Teplota rosného bodu (dew_point)

Rosný bod má slabou pozitivní korelaci s výkonem 0,13. Teplota rosného bodu je užitečná pro předpověď tvorby rosy a mlhy, která snižuje průchodnost slunečního záření atmosférou.

Experimenty však ukázaly, že rosný bod nemá na predikci výkonu zásadní vliv. Pouze v případě, že by nebyla k dispozici data o vlhkosti, by stálo za zvážení zahrnout tuto proměnnou do modelu.



Obr. 24. Korelační matice vstupních proměnných.




Obr. 25. Korelační matice ostatních proměnných.

8 Zpracování vstupních rysů


Pro správné učení modelu je nutné provést vhodnou normalizaci proměnných, aby byl schopen efektivně rozpoznávat vzory v datech. Cílem této kapitoly je transformovat distribuci všech proměnných co nejblíže normálnímu rozdělení a následně je normalizovat do intervalu $\{-1; 1\}$.

8.1 Sluneční záření

Histogram slunečního záření (Graf 17) vykazuje pravostrannou šikmost a obsahuje mnoho nulových hodnot, což by mohlo vést ke zkreslení predikcí modelu. Proto je nejprve aplikována transformace Yeo-Johnson, která upravuje distribuci dat směrem k normálnímu rozložení. I po této úpravě zůstává vyšší počet nulových hodnot, avšak rozložení zbývajících dat je vyváženější. Následně je provedena Min-Max normalizace, která škáluje hodnoty do intervalu $\{-1, 1\}$. Graf 18 zobrazuje distribuci hodnot RAD po aplikaci těchto metod.




Graf 17. Histogram hodnot slunečního záření (RAD).




Graf 18. Histogramy RAD po transformaci Yeo-Johnson (vlevo) a následné normalizaci Min-Max (vpravo).

8.2 Výkon

Histogram výkonu (Graf 19) má téměř stejný tvar jako histogram slunečního záření, neboť výkon FVE přímo souvisí s intenzitou dopadajícího slunečního záření. Vykazuje rovněž pravostrannou šikmost a vysoký výskyt nulových hodnot, proto se na jeho hodnoty aplikují stejné metody. Nejprve se aplikuje transformace Yeo-Johnson pro úpravu distribuce směrem k normálnímu rozložení a následně Min-Max normalizace pro škálování do intervalu $\{-1, 1\}$. Graf 20 zobrazuje distribuci hodnot výkonu po aplikaci těchto metod.




Graf 19. Histogram hodnot výkonu.



Graf 20. Histogramy výkonu po transformaci Yeo-Johnson (vlevo) a následné normalizaci Min-Max (vpravo).

8.3 Teplota panelů


Histogram teploty panelů (Graf 21) vykazuje přibližně normální rozložení. Teploty se pohybují v širokém rozmezí přibližně od -20°C do 55°C , přičemž nejčastější hodnoty se pohybují kolem 0 až 10°C . Jelikož data jsou už téměř normálně rozložena aplikuje se na ně pouze Min-Max normalizace do požadovaného intervalu $\langle -1, 1 \rangle$.



Graf 21. Histogram teploty panelů (vlevo) a Min-Max normalizaci (vpravo).

8.4 Koncentrace ozónu

Histogram (Graf 22, vlevo) zobrazuje rozložení koncentrace ozónu [$\mu\text{g}/\text{m}^3$]. Vykazuje téměř normální distribuci se středem kolem $60 \mu\text{g}/\text{m}^3$, a proto je na data aplikována pouze min-max normalizace, která je škáluje do intervalu $\langle -1, 1 \rangle$ (Graf 22, vpravo).




Graf 22. Histogram koncentrace ozónu (vlevo) a Min-Max normalizaci (vpravo).


8.5 Vlhkost vzduchu

Histogram vlhkosti vzduchu (Graf 23) ukazuje, že vyšší hodnoty vlhkosti (nad 80 %) jsou častější než nižší hodnoty. Pro co nejefektivnější učení modelu byla aplikována transformace Yeo-Johnson, která upravuje rozložení dat tak, aby se více blížilo normálnímu rozdělení.

Následně byla na transformovaná data aplikována Min-Max normalizace, která škáluje hodnoty do intervalu $\{-1, 1\}$. Graf 24 znázorňuje výsledky těchto transformačních kroků – levý histogram ukazuje data po Yeo-Johnson transformaci, zatímco pravý histogram zobrazuje jejich distribuci po normalizaci.



Graf 23. Histogram vlhkosti vzduchu.




Graf 24. Histogram vlhkosti vzduchu po Yeo-Johnson transformaci (vlevo) a následné Min-Max normalizaci (vpravo).

8.6 Oblačnost


Histogram oblačnosti (Graf 25) vykazuje dvojvrcholové rozdělení, přičemž nejčastějšími hodnotami jsou 0 % a 100 %. To naznačuje, že obloha bývá nejčastěji buď zcela jasná, nebo zcela zatažená.

Pro zlepšení rozložení dat pro model byla aplikována Yeo-Johnson transformace, která je určena k přiblížení distribuce normálnímu rozdělení. Nicméně, jak ukazuje Graf 26 (vlevo), transformace nedosáhla výrazného zlepšení, protože extrémní hodnoty stále dominují.

Následně byla aplikována standardní z-normalizace, která převádí hodnoty na z-skóre s průměrem 0 a směrodatnou odchylkou 1. Tato metoda umožňuje lepší zachování variability dat oproti Min-Max normalizaci, která by mohla extrémní hodnoty příliš stlačit. Jak ukazuje Graf 26 (vpravo), základní tvar distribuce zůstal zachován, zatímco hodnoty byly přizpůsobeny pro efektivnější vstup do modelu.




Graf 25. Histogram oblačnosti.



Graf 26. Histogram oblačnosti po Yeo-Johnson transformaci (vlevo) a následné Min-Max normalizaci (vpravo).

8.7 Povrchový atmosférický tlak


Histogram povrchového atmosférického tlaku (Graf 27, vlevo) ukazuje, že hodnoty se pohybují v rozmezí 950–1010 hPa, přičemž nejčastěji se vyskytují mezi 985–990 hPa. Rozdělení dat je přibližně normální, a proto byla aplikována pouze Min-Max normalizace, která škáluje hodnoty do intervalu $\{-1, 1\}$ (Graf 27, vpravo).




Graf 27. Histogram povrchového atmosférického tlaku (vlevo) a Min-Max normalizaci (vpravo).

8.8 Prachové částice PM10

Histogram (Graf 28) ukazuje rozložení koncentrací prachových částic PM10 [$\mu\text{g}/\text{m}^3$]. Data vykazují pravostranně šikmou distribuci s vyšší četností nižších hodnot. Proto byla aplikována transformace Yeo-Johnson (Graf 29, vlevo), která data přiblížila normálnímu rozložení. Následně byla na transformovaná data aplikována min-max normalizace, která hodnoty škáluje do intervalu $\{0, 1\}$ (Graf 29, vpravo).




Graf 28. Histogram prachových částic.



Graf 29. Histogram prachových částic po Yeo-Johnson transformaci (vlevo) a následné Min-Max normalizaci (vpravo).

8.9 Složky větru ve směru východ-západ a sever-jih

Hodnoty rychlosti větru ve směru východ-západ (Graf 30, horní řada, vlevo) se pohybují přibližně v rozmezí -10 až 10 m/s. Ve směru sever-jih (Graf 30, dolní řada, vlevo) jsou hodnoty podobně rozložené, přibližně od -12 do 12 m/s. Oba histogramy vykazují přibližně normální rozdělení, a proto byla na data aplikována Min-Max normalizace, která přeškáluje hodnoty do intervalu $(-1; 1)$ (Graf 30, pravý sloupec).




Graf 30. Histogramy rychlosti větru ve směru východ–západ (horní řada) a sever–jih (dolní řada) před a po normalizaci.

8.10 Časové proměnné

Časové proměnné byly získány transformací časových záznamů pomocí sinusové a kosinusové funkce. Graf 31 zobrazuje histogramy těchto transformovaných veličin.

U hodinových proměnných (`sin_hour`, `cos_hour`) je patrná vyšší četnost hodnot ± 1 , což odpovídá vlastnostem trigonometrických funkcí. Tyto funkce dosahují extrémních hodnot při půlnoci (00:00) a poledni (12:00), kdy se změna funkční hodnoty v čase zpomaluje.

Podobný vzorec lze pozorovat u proměnných `sin_day_of_year` a `cos_day_of_year`, kde jsou hodnoty odpovídající začátku a konci roku četnější. Vzhledem k tomu, že transformované časové proměnné se již nacházejí v intervalu $\langle -1; 1 \rangle$, není nutné provádět další normalizaci.



Graf 31. Histogramy časových proměnných sin_hour, cos_hour, sin_day_of_year a cos_day_of_year.

9 Tvorba modelů pro predikci výkonu FVE

Tato kapitola se věnuje tvorbě a porovnání různých přístupů k predikci výkonu fotovoltaické elektrárny (FVE). Modely se postupně vyvíjejí od statistického přístupu založeného na historických datech, přes základní fyzikální výpočty, až po pokročilé metody využívající neuronové sítě.

V první fázi je využit statistický přístup, kde je výkon predikován jako zprůměrovaná hodnota odpovídající konkrétní hodině dne na základě historických dat z trénovací sady, která pokrývá téměř čtyři roky. Tento referenční model reflektuje sezónní vzorce a představuje jednoduchý způsob predikce.

Dále je sestaven referenční model, který vychází z teoretického výpočtu výkonu na základě intenzity slunečního záření, účinnosti panelů a jejich orientace.

Následně je model rozšířen o korekční faktor IAM, který zohledňuje úhel dopadu slunečního záření (AOI), přičemž oba parametry jsou vypočítány pomocí knihovny pvlib. Nejprve je určena hodnota AOI, která udává úhel mezi normálou panelu a směrem dopadajícího slunečního záření. Z této hodnoty je následně vypočítán modifikátor IAM, který nahrazuje standardní kosinovou korekci a přesněji reflektuje optické ztráty v závislosti na úhlu dopadu slunečního záření na panely.

V závěru kapitoly jsou představeny dva modely založené na hlubokém učení, které umožňují predikci výkonu na základě historických hodnot výkonu a meteorologických rysů. Tento model predikuje výkon na následujících 8 hodin, přičemž je dále rozšířen o meteorologické rysy získávané z předpovědi počasí s predikčním horizontem až na 24 hodin dopředu.

Trénovací sada zahrnuje data z let 2020 až 2024, avšak bez období vyhrazeného pro testovací sadu, která představuje posledních 10 % dostupných dat. Testovací sada obsahuje 3 507 záznamů pokrývajících období od 7. srpna 2023 (21:00) do 31. prosince 2023 (23:00). Pro zajištění konzistentního vyhodnocení byly všechny vytvořené modely testovány na této stejné sadě. Ačkoli referenční modely (s výjimkou statistického modelu založeného na průměrných hodnotách) predikují výkon pro aktuální časový okamžik, zatímco neuronové modely predikují výkon pro následující hodiny, testování bylo provedeno jednotně na stejné testovací sadě, aby bylo možné mezi modely provést co nejobjektivnější srovnání.

V této kapitole jsou prezentovány pouze modely, které v dané kategorii dosahovaly nejlepších výsledků. Při jejich tvorbě byly testovány různé kombinace dostupných meteorologických proměnných, přičemž do finální podoby modelů byly zahrnuty ty, které vedly k nejpřesnějším predikcím.

Cílem této analýzy je porovnat přesnost jednotlivých modelů a identifikovat nejvhodnější přístup pro danou datovou sadu. K vyhodnocení jejich predikcí jsou použity metriky sMAPE, MAE, MBE a koeficient determinace R^2 , které jsou uvedeny v kapitole 5.7 (metrika MAPE nebyla použita kvůli nulovým výkonům FVE, které by vedly k dělení nulou). Tyto metriky poskytují komplexní pohled na přesnost modelů z různých perspektiv.

9.1 Referenční model na základě historických průměrů

Tento referenční model, který predikuje výkon na základě historických průměrů výkonů pro danou hodinu a den v roce, bez zohlednění aktuálních meteorologických podmínek, sice poskytuje určitou úroveň predikce výkonu FVE, avšak jeho přesnost je výrazně nižší ve srovnání s výše uvedenými referenčními fyzikálními modely.


Tabulka 1 shrnuje hodnotící metriky modelu. Model vykazuje vysoké chyby: relativní chyba sMAPE dosahuje 80 %, absolutní průměrná chyba MAE činí 77,78 kW, model systematicky podhodnocuje predikce s MBE -22,81 kW a koeficient determinace R^2 je na hodnotě 0,64, což značí výrazně horší schopnost modelu vysvětlit variabilitu skutečných hodnot výkonu.

Obecně tento model využívající průměry výkonů pro danou hodinu vykazuje nižší přesnost predikcí, zejména v porovnání s modely využívajícími korekční koeficient IAM. Jeho výhodou však je, že pro své predikce nevyžaduje žádné meteorologické vstupy, a proto je schopen predikovat výkon i v delším časovém horizontu, nejen pro hodiny, u nichž jsou k dispozici aktuální meteorologická data.


Graf 32 resp. Graf 33 zobrazuje srovnání predikovaného výkonu s historickými průměry (oranžová čárkovaná čára) a skutečného výkonu (modrá spojitá čára). Je vidět, že predikovaný výkon má výrazně vyhlazenější průběh, což je důsledek použití průměrných hodnot. Tento model proto není schopen dobře zachytit denní výkyvy způsobené změnami oblačnosti či jinými faktory. Jeho predikce jsou tedy nejspolehlivější za stabilních podmínek, avšak při proměnlivé oblačnosti nebo jiných dynamických změnách jeho přesnost klesá.

Tabulka 1. Hodnoty chybových metrik pro predikční model výkonu využívající průměrné hodnoty

Metrika	Hodnota
sMAPE	80 %
MBE	-22,81 kW
R^2	0,64
MAE	77,78 kW



Graf 32. Srovnání skutečného a predikovaného výkonu FVE z průměrných historických hodnot.



Graf 33. Srovnání skutečného a predikovaného výkonu FVE z průměrných hodnot pro prvních 300 hodnot v testovací sadě.

9.2 Referenční fyzikální model

Pro výpočet predikovaného výkonu FVE byl použit vzorec z Rovnice 3 uvedený v teoretické části. Na základě tohoto vztahu byly určeny predikované hodnoty výkonu pro jednotlivé hodiny, přičemž jako vstupní hodnota bylo použito průměrné globální sluneční


záření Me z datové sady Solarmon. Za úhel β byla dosazena hodnota 35° , která odpovídá sklonu panelů.

Výsledné metriky (Tabulka 2) ukazují, že model vykazuje poměrně vysokou chybovost. Relativní chyba sMAPE dosahuje 75,1 %, absolutní chyba MAE činí 34,02 kW a záporná hodnota MBE -28,46 kW potvrzuje, že model systematicky podhodnocuje výkon FVE. Přesto koeficient determinace R^2 na úrovni 0,93 naznačuje, že model dokáže zachytit značnou část variability skutečného výkonu a poskytuje relativně přesnou aproximaci.


Graf 34 resp. Graf 35 vizualizuje výsledky modelu, přičemž modrá čára reprezentuje skutečně naměřené hodnoty výkonu FVE a oranžová přerušovaná čára odpovídá predikovanému výkonu. Z grafu je patrné, že model má tendenci systematicky podhodnocovat výkon, což odpovídá negativní hodnotě MBE. Zároveň model nedokáže dostatečně přesně zachytit extrémní špičky výkonu, což přispívá k vyšší relativní chybovosti vyjádřené metrikou sMAPE.

Tabulka 2. Hodnoty chybových metrik pro predikční fyzikální model výkonu s Me.

Metrika	Hodnota
sMAPE	75,1 %
MBE	-28,46 kW
R^2	0,93
MAE	34,02 kW



Graf 34. Porovnání skutečného a predikovaného výkonu fyzikálním modelem s využitím Me.



Graf 35. Porovnání skutečného a predikovaného výkonu fyzikálním modelem s využitím Me pro prvních 300 hodnot v testové sadě.

9.3 Referenční fyzikální model s využitím korekčního koeficientu IAM

V této části byl vytvořen fyzikální predikční model výkonu FVE, který oproti předchozímu přístupu lépe zohledňuje skutečné podmínky dopadu slunečního záření na panely. Dřívější model dosazoval do Rovnice 3 úhel dopadu slunečního záření ($\beta = 35^\circ$),

což odpovídá sklonu panelů, ale nezohledňovalo dynamické změny polohy slunce během dne.


Pro zpřesnění výpočtu byl nyní místo konstantní hodnoty $\cos(\beta)$ do této rovnice dosazen korekční koeficient IAM (Incidence Angle Modifier), který vyjadřuje, jak se absorpce slunečního záření mění v závislosti na úhlu dopadu (AOI, Angle of Incidence), tedy úhlu mezi normálou panelu a směrem dopadajícího slunečního záření. Hodnota IAM byla určena pomocí fyzikálního modelu ASHRAE.

Tyto hodnoty byly vypočteny pomocí funkcí z knihovny pvlib na základě znalosti azimutu a zenitu slunce pro danou hodinu a orientace panelů. Tento přístup umožňuje nejen realističtější modelování změn dopadajícího slunečního záření, ale také zohlednění ztrát způsobených odrazivostí panelů, čímž zpřesňuje odhad výkonu fotovoltaické elektrárny.


Graf 36 a Graf 37 ukazují, že nový model využívající korekční koeficient IAM lépe sleduje špičky skutečného výkonu, i když stále dochází k podhodnocování, zejména v extrémních hodnotách. Základní metriky modelu shrnuje Tabulka 3. Oproti předchozímu fyzikálnímu modelu se sMAPE zlepšila z 75,1 % na 56,6 % a MAE se snížila z 34,02 kW na 17,28 kW. MBE zůstalo záporné, avšak podhodnocování výkonu se snížilo z -28,46 kW na -6,43 kW. R^2 vzrostlo z 0,93 na 0,97, což znamená, že nový model lépe vysvětluje variabilitu dat.

Tabulka 3. Hodnoty chybových metrik pro predikční fyzikální model výkonu využívající IAM pro Me.

Metrika	Hodnota
sMAPE	56,6 %
MBE	-6,43 kW
R^2	0,97
MAE	17,28 kW



Graf 36. Srovnání skutečného a predikovaného výkonu FVE s korekcí úhlu pomoci IAM pro Me.



Graf 37. Srovnání skutečného a predikovaného výkonu FVE s korekcí úhlu pomoci IAM pro Me pro prvních 300 hodnot v testovací sadě.


9.4 Modely s využitím neuronových sítí

V této kapitole jsou představeny dva predikční modely. První uvedený model k predikci výkonu FVE využívá pouze historická data, zatímco druhý model rozšiřuje vstupní sadu rysů o meteorologické údaje získané z předpovědních modelů počasí.

Bylo provedeno mnoho experimentů s různými vstupními rysy a architekturami modelu. Pro zajištění konzistence a replikovatelnosti výsledků byla ve všech

experimentech použita stejná počáteční hodnota generátoru náhodných čísel (seed), což zajistilo konzistentní inicializaci vah modelu. Přehled vstupních rysů je uveden v kapitolách 7.5 (Korelační analýza) a 8 (Zpracování vstupních rysů).

Nejslibnější architekturou obou modelů (Obr. 26) se ukázala být kombinace konvoluční vrstvy a LSTM, která efektivně zachycuje krátkodobé i dlouhodobé vzory v datech. Konvoluční vrstva extrahuje lokální vzory a krátkodobé korelace mezi vstupními proměnnými, zatímco LSTM vrstva modeluje dlouhodobé závislosti a sezónní cykly.



Obr. 26. Architektura predikčního modelu s vrstvami Conv1D a LSTM.

9.4.1 Model pro predikci výkonu na následujících 8 hodin na základě historických dat

Vstupní vrstva modelu očekává tenzor s rozměry 24 časových kroků $\times$ 14 vstupních rysů, mezi něž patří: výkon (output), globální sluneční záření (RAD), časové proměnné (sin_day_of_year, cos_day_of_year, cos_hour, sin_hour), složky větru (wind_u, wind_v), povrchový atmosférický tlak (surface_pressure), teplota panelů (tp), oblačnost (Cloud_Cover), vlhkost vzduchu (humidity), prachové částice (PM10) a ozon (Ozone).

Optimalizace hyperparametrů byla provedena pomocí Keras Tuner s Bayesovskou optimalizací. K učení modelu byla využita křížová validace s rozšiřujícím se oknem, přičemž počet epoch byl stanoven na 45 pro první běh a 35 pro následné. Nejlepších výsledků bylo dosaženo s optimalizátorem ADAM, ztrátovou funkcí MAE, rychlostí učení 0,0005 a velikostí dávky 64. Optimalizovaný model obsahuje konvoluční vrstvu se 272 filtry (jádro 2, aktivace ReLU, same padding), následovanou LSTM vrstvou s 1472 jednotkami a rekurentním dropoutem 10 %, což zlepšuje generalizaci. Výstupní Dense vrstva odpovídá počtu hodin predikce (v tomto případě 8 hodin) a využívá lineární aktivační funkci. Tabulka 4 shrnuje optimalizované hyperparametry modelu.

Graf 38 zobrazuje průběh ztrátové funkce během trénování modelu. Zobrazeny jsou dvě křivky: trénovací ztráta (modrá) a validační ztráta (červená), přičemž zelená čárkovaná čára vyznačuje nejnižší dosaženou hodnotu validační ztráty. Hodnoty ztrátové funkce u obou křivek v prvních epochách rychle klesají, což naznačuje, že se model efektivně učí vzory z dat. Náhlé nárůsty validační ztráty mohou být důsledkem použití metody rozšiřujícího se okna. S rostoucím počtem epoch se křivky stabilizují a ztráta dosahuje nízkých hodnot, což svědčí o dobré konvergenci modelu. Skutečnost, že validační ztráta sleduje trend trénovací ztráty bez výrazného nárůstu, naznačuje, že model se nepřeučil a zachovává dobrou schopnost generalizace.

Tabulka 5 uvádí jednotlivé metriky modelu pro jednotlivé hodiny. Z hodnot sMAPE, MBE, R^2 a MAE je zřejmé, že predikční model dosahuje nejvyšší přesnosti predikce výkonu v první hodině, kde je hodnota sMAPE pouze 3,60 % s MAE o 6,90 kW a R^2 dosahující hodnoty 1. Tyto metriky naznačují téměř perfektní shodu mezi predikovaným a skutečným výkonem. S rostoucími hodinami se však predikce stává méně přesnou, přičemž hodnoty sMAPE vzrůstají až na 26,83 % v osmé hodině. MBE metrika ukazuje, že model v prvních hodinách výkon mírně nadhodnocuje, zatímco od třetí hodiny dochází k jeho podhodnocování. Podobně roste i MAE, která dosahuje až 49,26 kW, což odráží narůstající rozdíly mezi predikovanými a skutečnými hodnotami výkonu. R^2 postupně klesá až na 0,82, což signalizuje zhoršení schopnosti modelu vysvětlit variabilitu hodnot skutečného výkonu v průběhu času.

Graf 39 a Graf 40 zobrazují a srovnávají průběhy predikcí a skutečného výkonu v jednotlivých hodinách. S rostoucím predikčním horizontem model čelí větším obtížím při přesném zachycení náhlých špiček výkonu.


Graf 41 představuje sadu osmi SHAP (SHapley Additive exPlanations) grafů, které zobrazují průměrnou důležitost jednotlivých rysů v predikci výkonu FVE pro každou hodinu, provedených na prvních sto hodnotách testovací sady. Z grafů vyplývá, že nejvýznamnějším rysem je pro první hodiny globální sluneční záření RAD, které má výrazně vyšší vliv na predikci než ostatní rysy. S přibývajícím časem klesá význam globálního slunečního záření RAD a naopak roste důležitost časových rysů `cos_hour`, `sin_hour` popisující sezónních trendy výkonu FVE.

Tabulka 4. Výčet hyperparametrů modelu.


Hyperparametr	Hodnota	Poznámka
Počet filtrů CNN	272	Velikost jádra 2
Počet LSTM jednotek	1472	Rekurentní dropout 10 %
Aktivační funkce CNN	ReLU	
Aktivační funkce výstupu	Lineární	
Optimalizátor	ADAM	Rychlost učení 0,0005
Ztrátová funkce	MAE	
Počet epoch (první běh)	45	
Počet epoch (další běhy)	35	
Velikost dávky	64	
Křížová validace	5 kroků	Rozšiřující se okno
Počet vstupních rysů	14	Časová řada 24 hodnot
Predikční horizont	8 hodin	

Tabulka 5. Hodnotící metriky pro model predikující výkon na následujících 8 hodin


Hodina	sMAPE (%)	MBE (kW)	R ²	MAE (kW)
1. hodina	3,60	5,49	1	6,90
2. hodina	16,21	1,71	0,95	25,42
3. hodina	20,76	-4,85	0,91	33,77
4. hodina	22,96	-6,70	0,89	38,29
5. hodina	24,52	-13,20	0,86	42,29
6. hodina	25,35	-13,10	0,84	45,26
7. hodina	26,54	-13,97	0,82	48,70
8. hodina	26,83	-14,22	0,82	49,26




Graf 38. Průběh ztrátové funkce.



Graf 39. Průběhy predikcí se skutečným výkonem v jednotlivých hodinách.



Graf 40. Průběhy predikcí a skutečných výkonů v jednotlivých hodinách pro prvních 300 hodnot v testovací sadě.



Graf 41. Průměrná důležitost rysů dle SHAP analýzy.

9.4.2 Model s predikcí výkonu se zahrnutím předpovědi počasí

Podobně jako předchozí model, i tento využívá kombinaci konvoluční vrstvy s LSTM vrstvou (Obr. 26), přičemž je rozšířena vstupní sada o predikované meteorologické rysy na následujících 24 hodin. Konkrétně se jedná o okolní teplotu (T2M), sluneční záření (RAD), vlhkost (humidity), povrchový tlak (surface_pressure), oblačnost (Cloud_Cover), složky větru (wind_u a wind_v), koncentraci ozonu (Ozone), koncentraci prachových částic (PM10) v atmosféře a časové proměnné (sin_hour, sin_day_of_year, cos_hour, cos_day_of_year).

Pro nalezení optimálních hyperparametrů modelu byl opět použit nástroj Keras Tuner s Bayesovskou optimalizací. K učení modelu byla opětovně využita křížová validace s rozšiřujícím se oknem, přičemž počet epoch byl stanoven na 40 pro první běh a 50 pro následné běhy. Optimalizovaný model obsahuje konvoluční vrstvu se 96 filtry (jádro 2, aktivace ReLU, same padding), následovanou LSTM vrstvou s 2816 jednotkami a rekurentním dropoutem 10 %. Počet neuronů ve výstupní Dense vrstvě odpovídá predikčnímu horizontu, který byl v tomto případě stanoven na 24 hodin a vrstva využívá lineární aktivační funkci. Pro zbývající hyperparametry byly zachovány původní hodnoty, které se osvědčily v předchozím modelu, konkrétně optimalizátor ADAM, ztrátová funkce MAE, rychlost učení 0,0005 a velikost dávky 64. Tabulka 6 shrnuje optimalizované hyperparametry modelu.

Tabulka 7 ukazuje, že model vykazuje velmi nízké hodnoty sMAPE, což naznačuje vysokou přesnost predikcí. MBE se pohybuje převážně v okolí nulových hodnot, což znamená, že model vykazuje vyvážený přístup k nadhodnocování a podhodnocování výkonu. R^2 se stabilně drží na hodnotě 1, což svědčí o velmi dobré schopnosti modelu vysvětlit variabilitu skutečného výkonu. Hodnota MAE klesá s postupem času, přičemž v poslední hodině dosahuje hodnoty 3,94 kW, což ukazuje na stabilní predikci výkonu i s rostoucím časovým horizontem.

Graf 43 resp. Graf 44 ukazují průběhy predikcí a skutečných hodnot pro jednotlivé hodiny. Průběh predikované křivky velmi úzce kopíruje skutečný výkon včetně pokrytí krátkodobých výkyvů v rámci celého predikovaného dne.

Graf 42 znázorňuje průběh ztrátové funkce během trénování, kde je patrný počáteční prudký pokles, svědčící o efektivní inicializaci modelu a rychlém osvojování vzorců v datech. S rostoucím počtem epoch se tempo poklesu zpomaluje a model postupně

konverguje. Trénovací ztráta klesá plynule, zatímco validační ztráta vykazuje drobné fluktuace, přičemž kolem 140 a 225 epochy dochází ke zvýšené variabilitě, pravděpodobně v důsledku strategie rozšiřovacího okna, kdy se trénovací sada rozšiřuje o nové vzorky. Tento efekt se však postupně vytrácí a validační chyba se stabilizuje. V závěrečné fázi se obě křivky ustálí na nízkých hodnotách s minimálním rozdílem, což svědčí o dobré generalizaci modelu a vhodně zvolené trénovací strategii.


Tabulka 6. Výčet hyperparametrů modelu využívající předpověď počasí.

Hyperparametr	Hodnota	Poznámka
Počet filtrů CNN	96	Velikost jádra 2
Počet LSTM jednotek	2816	Rekurentní dropout 10 %
Aktivační funkce CNN	ReLU	
Aktivační funkce výstupu	Lineární	
Optimalizátor	ADAM	Rychlost učení 0,0005
Ztrátová funkce	MAE	
Počet epoch (první běh)	40	
Počet epoch (další běhy)	50	
Velikost dávky	64	
Křížová validace	10 kroků	Rozšiřující se okno
Počet vstupních rysů	27	Časová řada 24 hodnot
Predikční horizont	24 hodin	


Tabulka 7. Hodnotící metriky pro model s využitím předpovědi počasí predikující výkon na následujících 24 hodin.

Hodina	sMAPE (%)	MBE (kW)	R2	MAE (kW)
1. hodina	3,95	2,20	1	5,31
2. hodina	4,49	3,55	1	6,54
3. hodina	4,12	3,61	1	5,86
4. hodina	3,90	3	1	5,29
5. hodina	3,89	1,45	1	4,95
6. hodina	3,78	0,34	1	4,69
7. hodina	3,72	1,40	1	4,69
8. hodina	3,65	-1,70	1	4,94
9. hodina	3,44	-0,88	1	4,68


10. hodina	3,58	-0,21	1	4,44
11. hodina	3,47	-0,79	1	4,46
12. hodina	3,50	1,34	1	4,65
13. hodina	3,59	0,11	1	4,29
14. hodina	3,46	0,34	1	4,10
15. hodina	3,50	1,32	1	4,35
16. hodina	3,45	2,15	1	4,62
17. hodina	3,40	2,31	1	4,70
18. hodina	3,29	2,38	1	4,37
19. hodina	3,43	1,47	1	4,26
20. hodina	3,29	2,02	1	4,32
21. hodina	3,14	2,47	1	4,38
22. hodina	3,25	2,07	1	4,26
23. hodina	3,32	2,03	1	4,33
24. hodina	3,41	-0,30	1	3,94



Graf 42. Průběh ztrátové funkce.



Graf 43. Průběhy predikcí se skutečným výkonem v jednotlivých hodinách.



Graf 44. Průběhy predikcí a skutečných výkonů v jednotlivých hodinách pro prvních 300 hodnot v testovací sadě.

10 Výsledky a diskuse

Tabulka 8 přehledně uvádí výsledné hodnotící metriky pro všechny vytvořené modely. Nejhorších výsledků dosahuje model, který predikuje výkon jako průměrnou historickou hodnotu dané hodiny ve všech předchozích letech, což vede k průměrné sMAPE 80 %. Vysoká chybovost tohoto přístupu je očekávaná, protože model nezohledňuje aktuální meteorologické podmínky a změny v dlouhodobém trendu výkonu FVE.

Fyzikální model své predikce vypočítává na základě fyzikální *Rovnice 3* popisující vztah pro výpočet výkonu fotovoltaických panelů na základě intenzity dopadajícího slunečního záření, sklonu panelů, jejich účinnosti a velikosti aktivní plochy. Model poskytuje lepší výsledky než historické průměry, ale stále vykazuje poměrně vysokou chybu sMAPE činí 75,1 %, průměrná MBE je -28,46 kW a střední absolutní chyba dosahuje 34,02 kW.

Vyšší přesnosti predikcí výkonu dosahuje fyzikální model, který v *Rovnici 3* nahrazuje konstantní hodnotu $\cos(\beta)$ korekčním koeficientem IAM. Ten zohledňuje skutečný úhel dopadu slunečního záření a jeho vliv na množství energie absorbované fotovoltaickými panely. Model vykazuje celkově lepší metriky, sMAPE 56,6 %, MAE 17,28 kW a výrazně snižuje systematickou podhodnocenost predikcí na -6,43 kW.

Zcela odlišných výsledků dosahují modely využívající neuronové sítě s vhodně vybranými a zpracovanými vstupy. Model, který ke svým predikcím využívá pouze historická data, dosahuje pro první hodinu sMAPE 3,60 %. Avšak jak se časový horizont rozšiřuje, model už nedokáže efektivně zohlednit dynamicky se měnící meteorologické podmínky. V predikčním horizontu osmi hodin dosahuje průměrná hodnota sMAPE 20,84 %, průměrná absolutní chyba MAE dosahuje 36,23 kW a systém stále podhodnocuje výkon s průměrnou MBE -7,35 kW. Model vysvětluje 88 % variability skutečných hodnot výkonu.

Nejpřesnější predikce poskytuje model využívající neuronovou síť, která kromě historických dat zahrnuje i předpověď počasí pro dané predikované hodiny výkonu. Tento model dosahuje na celém predikčním horizontu 24 hodin průměrné sMAPE pouhých 3,58 %, průměrné MBE 1,32 kW a jeho koeficient determinace R^2 dosahuje hodnoty 1, což znamená téměř dokonalou shodu predikovaných hodnot se skutečnými daty. Tento výsledek ukazuje, že kombinace historických dat s aktuálními meteorologickými

podmínkami umožňuje modelu dosáhnout nejvyšší možné přesnosti (samozřejmě záleží na přesnosti předpovědi počasí).

Celkové výsledky potvrzují, že neuronové sítě, zejména v kombinaci s předpovědí počasí, jsou nejvhodnější metodou pro krátkodobou predikci výkonu fotovoltaických elektráren. Naopak tradiční metody, jako jsou fyzikální modely bez dodatečných korekcí nebo jednoduché historické průměry, vykazují výrazně horší výsledky.

Tabulka 8. Přehled hodnotících metrik pro všechny modely.

Model	Časový horizont	Průměrná sMAPE (%)	Průměrná MBE (kW)	Průměrná R^2	Průměrná MAE (kW)
Fyzikální model	1 hodina	75,1	-28,46	0,93	34,02
Fyzikální model s využitím IAM	1. hodina	56,6	-6,43	0,97	17,28
Historické průměry	-	80	-22,81	0,64	77,78
Neuronové sítě – historická data	8 hodin	20,84	-7,35	0,88	36,23
Neuronové sítě – s předpovědí počasí	24 hodin	3,58	1,32	1	4,68

11 Závěr

Cílem této práce bylo vytvořit model pro co nejpřesnější krátkodobou predikci výkonu fotovoltaické elektrárny ABA.

Teoretická část se nejprve zaměřila na obecné principy fungování fotovoltaických elektráren a faktory ovlivňující jejich výkon. Následně byly představeny kapitoly o strojovém a hlubokém učení, které tvoří základ nejpřesnějších predikčních modelů vyvinutých v této práci.

V rámci práce byly implementovány různé modely, přičemž nejzajímavější z každé kategorie byly shrnuty a popsány. Konkrétně byly vytvořeny modely využívající historické průměry, fyzikální výpočty a neuronové sítě, a to jak na základě historických dat, tak i s využitím předpovědi počasí.

Součástí práce bylo také nasazení nejlepšího modelu do provozu. Model je dostupný na adrese: <https://huggingface.co/spaces/Kubas126cz/FVEABA> a umožňuje predikci výkonu na následujících pět dní (včetně aktuálního dne), což odpovídá dostupnosti meteorologické předpovědi. Zároveň je možné i zpětně predikovat výkon elektrárny na základě historických meteorologických dat.

Výsledné modely spolu s transformery pro zpracování vstupních rysů a odpovídajícím zdrojovým kódem jsou uloženy na v příloze uvedeném CD, které je součástí této práce.

Možné způsoby zvýšení přesnosti predikce zahrnují trénování modelu na kratších časových intervalech, například v 15minutových vzorcích, což by umožnilo lepší zachycení náhlých výkyvů výkonu FVE. Další možností je kombinace různých modelů, například propojení fyzikálních a neuronových modelů.

Získané výsledky mají praktické využití v oblasti optimalizace výkonu fotovoltaických elektráren a mohou sloužit jako základ pro další vývoj predikčních nástrojů v oblasti obnovitelných zdrojů energie.

12 Seznam použitých zdrojů

- [1] M. Libra, M. Kozelka, J. Šafránková, R. Belza, V. Poulek, V. Beránek, J. Sedláček, M. Zholobov, T. Šubrt, L. Severová, Agrivoltaics: dual usage of agricultural land for sustainable development, *Int Agrophys* 38 (2024) 121–126. <https://doi.org/10.31545/INTAGR/184133>.
- [2] Konrad Mertens, *Photovoltaics: Fundamentals, Technology, and Practice*, 2nd Edition, Wiley, Hoboken, New Jersey, USA, 2018.
- [3] Solar  power generation forecast , (n.d.). <https://www.kaggle.com/code/pythonafroz/solar-power-generation-forecast/notebook> (accessed September 28, 2024).
- [4] 7 factors that affect the performance of your solar system - Hoymiles, (n.d.). <https://www.hoymiles.com/resources/blog/7-factors-that-affect-the-performance-of-your-solar-system/> (accessed September 29, 2024).
- [5] V.P. Martin Libra, *Fotovoltaika, teorie i praxe využití solární energie*, 2009.
- [6] Factors Affecting PV Plants Performance | Seven Sensor, (n.d.). <https://www.sevensensor.com/factors-affecting-pv-plants-performance> (accessed September 29, 2024).
- [7] S.A. Solar Technology, Performance ratio - Quality factor for the PV plant, (n.d.).
- [8] How Is Solar Panel Efficiency Measured? - Technical Articles, (n.d.). <https://eepower.com/technical-articles/how-is-solar-panel-efficiency-measured/#> (accessed September 29, 2024).
- [9] How Is Solar Panel Efficiency Measured? - Technical Articles, (n.d.). <https://eepower.com/technical-articles/how-is-solar-panel-efficiency-measured/#> (accessed September 29, 2024).
- [10] Solar Performance and Efficiency | Department of Energy, (n.d.). <https://www.energy.gov/eere/solar/solar-performance-and-efficiency> (accessed September 29, 2024).
- [11] Why Don't Solar Panels Always Generate Their Rated Power Wattage?, (n.d.). <https://blog.ecoflow.com/us/why-dont-solar-panels-generate-rated-power-wattage/> (accessed September 29, 2024).
- [12] Factors Effecting PV Plant Performance, How to Monitor and Control/Mitigate Impact of Each Factor, (n.d.). <https://www.linkedin.com/pulse/factors-effecting-pv-plant-performancehow-monitor-impact-mukhtar> (accessed September 29, 2024).
- [13] Optimizing solar PV systems: Strategies to minimize shading impact | Solargraf, (n.d.). <https://www.solargraf.com/blog/optimizing-solar-pv-systems-strategies-to-minimize-shading-impact/> (accessed September 29, 2024).
- [14] How Do Temperature and Shade Affect Solar Panel Efficiency? | Boston Solar | MA, (n.d.). <https://www.bostonsolar.us/solar-blog-resource-center/blog/how-do-temperature-and-shade-affect-solar-panel-efficiency/> (accessed September 29, 2024).
- [15] Solar Panel Cleaning: The Key to Efficient Energy Conversion, (n.d.). <https://goingsolar.ie/blog/solar-panel-cleaning> (accessed September 29, 2024).
- [16] Jaká je vlastně životnost solárních panelů a jak je chránit? - Energosolar.cz, (n.d.). <https://www.energosolar.cz/jaka-je-vlastne-zivotnost-solarnich-panelu-a-jak-je-chranit/> (accessed September 30, 2024).
- [17] What is Inverter Efficiency? | inverter.com, (n.d.). <https://www.inverter.com/what-is-inverter-efficiency> (accessed October 1, 2024).

- [18] 12 types of Losses in Solar PV system | Bridgeway Power, (n.d.). <https://bridgewaypower.in/blog/12-types-of-losses-in-solar-pv-system> (accessed October 1, 2024).
- [19] Problem 41 To reduce losses from resistance... [FREE SOLUTION] | Vaia, (n.d.). <https://www.vaia.com/en-us/textbooks/physics/physics-and-technology-for-future-presidents-10-edition/chapter-6/problem-41-to-reduce-losses-from-resistance-electric-power-1/> (accessed October 1, 2024).
- [20] (PDF) Investigation of PV System Cable Losses, (n.d.). https://www.researchgate.net/publication/317701311_Investigation_of_PV_System_Cable_Losses (accessed October 1, 2024).
- [21] François Chollet, Deep learning v jazyku Python, 2., rozšířené vydání, Grada, 2023.
- [22] Aurélien Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems, 3rd Edition, O'Reilly Media; 3rd edition (October 4, 2022), 2022.
- [23] YeoJohnsonTransformer — 1.8.3, (n.d.). https://feature-engine.trainindata.com/en/1.8.x/user_guide/transformation/YeoJohnsonTransformer.html (accessed March 23, 2025).
- [24] MSE vs RMSE vs MAE vs MAPE vs R-Squared: When to Use?, (n.d.). https://vitalflux.com/mse-vs-rmse-vs-mae-vs-mape-vs-r-squared-when-to-use/?utm_source=chatgpt.com (accessed February 23, 2025).
- [25] A guide on regression error metrics (MSE, RMSE, MAE, MAPE, sMAPE, MPE) with Python code, (n.d.). https://sefidian.com/2022/08/18/a-guide-on-regression-error-metrics-with-python-code/?utm_source=chatgpt.com (accessed February 23, 2025).
- [26] R-squared in Linear Regression Models: Concepts, Examples, (n.d.). <https://vitalflux.com/r-squared-explained-machine-learning/> (accessed February 23, 2025).
- [27] Jak se počítá R-square a co to představuje? - Akademie EITCA, (n.d.). <https://cs.eitca.org/um%C4%9BI%C3%A1-intelligence/eitc-ai-mlp-strojov%C3%A9-u%C4%8Den%C3%AD-s-pythonem/programov%C3%A1n%C3%AD-strojov%C3%A9ho-u%C4%8Den%C3%AD/r-%C4%8Dtvercov%C3%A1-teorie/p%C5%99ezkoum%C3%A1n%C3%AD-zkou%C5%A1ky-r-%C4%8Dtvercov%C3%A1-teorie/jak-se-vypo%C4%8D%C3%ADt%C3%A1-r-na-druhou-a-co-to-p%C5%99edstavuje/> (accessed February 23, 2025).
- [28] BE - Mean Bias Error — Permetrics 2.0.0 documentation, (n.d.). https://permetrics.readthedocs.io/en/latest/pages/regression/MBE.html?utm_source=chatgpt.com (accessed February 24, 2025).
- [29] Martin Pilát, (n.d.). <https://martinpilat.com/cs/prirodou-inspirovane-algoritmy/neuronove-site-konvolucni-site-zpracovani-obrazu> (accessed March 7, 2025).
- [30] What is a Perceptron? What is the role of bias in a perceptron (or neuron)? - AIML.com, (n.d.). <https://aiml.com/what-is-a-perceptron/> (accessed March 7, 2025).
- [31] Introduction to Activation Functions in Neural Networks | DataCamp, (n.d.). <https://www.datacamp.com/tutorial/introduction-to-activation-functions-in-neural-networks> (accessed March 15, 2025).

- [32] Activation functions for Neural networks, (n.d.). <https://www.kaggle.com/code/shrutikunapuli/activation-functions-for-neural-networks> (accessed March 15, 2025).
- [33] Loss Function & Optimization | Kaggle, (n.d.). <https://www.kaggle.com/discussions/general/265294> (accessed March 7, 2025).
- [34] tensorflow-deep-learning/10_time_series_forecasting_in_tensorflow.ipynb at main · mrdbourke/tensorflow-deep-learning · GitHub, (n.d.). https://github.com/mrdbourke/tensorflow-deep-learning/blob/main/10_time_series_forecasting_in_tensorflow.ipynb (accessed February 6, 2025).
- [35] How To Do Time Series Cross-Validation In Python | Forecastegy, (n.d.). https://forecastegy.com/posts/time-series-cross-validation-python/?fbclid=IwZXh0bgNhZW0CMTEAAR1PwIKfXeJVSXZKU6J92Attn9TtInRzLoZGK7vf0W2qz8HCQ_YOx1R4VA_aem_D072vEAc5xz55Kd0AAIXWA (accessed February 23, 2025).
- [36] Understanding Time Series Cross-validation | by Subash Palvel | Medium, (n.d.). <https://subashpalvel.medium.com/understanding-time-series-cross-validation-1929c543d339> (accessed February 23, 2025).
- [37] Cross Validation of Time Series Models - Jose M Sallan blog, (n.d.). <https://jmsallan.netlify.app/blog/cross-validation-of-time-series-models/> (accessed February 23, 2025).
- [38] pvlib.iam.ashrae — pvlib python 0.9.0+0.g518cc35.dirty documentation, (n.d.). <https://pvlib-python.readthedocs.io/en/v0.9.0/generated/pvlib.iam.ashrae.html> (accessed March 10, 2025).
- [39] (PDF) Effect of Air Pressure on the Output of Photovoltaic Panel and Solar Illuminance (or Intensity), (n.d.). https://www.researchgate.net/publication/305943091_Effect_of_Air_Pressure_on_the_Output_of_Photovoltaic_Panel_and_Solar_Illuminance_or_Intensity (accessed March 10, 2025).

13 Přílohy

CD obsahující vytvořené modely